Qualitat de l'aire i impacte a la salut

Modelització Estadística

D5 - FINAL PROJECT DELIVERY

Mariona Casasnovas, Raul Castillo, Marc Delgado, Núria López i Joan Riera

CONTINGUT

1. **Introduction**

2. **Initial Statistics Analysis**

    2.1 Preprocessing

    2.2 Descriptive Statistics

3. **Generalized Linear Models (GLMz)**

    3.1 Numerical Response

    3.2 Binary Response

4. **Time series (TS)**

5. **Principal Components Analysi (PCA)**

6. **Clustering**

    6.1 Hierarchical Clustering

    6.2 Partitional Clustering

7. **Profiling of Clusters**

    7.1 Hierarchical Clustering

    7.2 Partitional Clustering

    7.3 Conclusions

8. **Conclusions**

9. **Expectation vs Reality**

    9.1 Gantt planejat i final

    9.2 Distribució planejada i final

1. Introduction

Problem

L'augment de la contaminació atmosfèrica, principalment en les àrees urbanes, ha provocat un increment en els problemes de salut pública. A més, el calentament global està fent que cada dia aquests problemes agafin cada vegada més i més importància.

Amb les variables que trobem en la nostra *database* utilitzant diversos estadístics podrem predir quin serà el risc per a la salut pública aquesta contaminació o perills atmosfèrics (com molta pluja) segons la temperatura, la humitat, les precipitacions, el vent…

Metadata

Url del database i procès de descàrrega:

https://www.kaggle.com/datasets/abdullah0a/urban-air-quality-and-health-impact-dataset

Per a descarregar la nostra base de dades cliqui en el link i ves a *download* (es requereix estar registrat a la web de *Kaggle*). Una vegada instal·lada, obri-la en excel (o el seu programa similar de preferència) i fes les modificacions adients per a arribar al format correcte.

Descripció de la *database*

La *database* seleccionada proporciona informació rellevant sobre qualitat de l'aire i el seus potentials effects negatius en la població de diverses ciutats estatunidenques. L'objectiu d'aquesta *dataset* és proporcionar un anàlisi dels factors ambientals que afecten a la salut pública, sobretot sobre les malalties respiratòries i cardiovasculars, com poden ser la pol·lució de l'aire, la temperatura i altres paràmetres atmosfèrics.

Aquesta *dataset* consisteix de 1000 files i 33 columnes, on cada fila representa una única observació de la qualitat de l'aire i el seu impacte sobre la salut per a una data i ciutat específica. Cada observació inclou la concentració de diversos contaminants atmosfèrics i el nombre d'ingressos hospitalaris mesurats en la ciutat, així permitint un detallat anàlisi de com la pol·lució de l'aire afecta la salut en diverses àrees urbanes.

Estructura bàsica de la matriu de dades

Nº d'individus: 1000

Nº de variables binàries: 2

Nº de variables numèriques : 22

Nº de variables qualitatives: 6

Nº de variables referents a dates: 3

Missing data: la nostra base de dada no té cap *missing data*

Descripción de las variables

VARIABLE	DESCRIPTION	TYPE	RANGE
DateTime	Timestamp of the recorded data	Temporal	(1/09/2023-21/09/2023)
City	The U.S. city where the data was recorded	Categorical	(Chicago, New York city, Phenix, Dalas, etc)
Temp_Max	Maximum temperature for the day (°F)	Numerical	(62.04-107,80)
Temp_Min	Minimum temperature for the day (°F)	Numerical	(49,11-91,64)
Temp_Avg	Average temperature for the day (°F)	Numerical	(55,55-99,85)
Temp_Range	Temperature range for the day (difference between max and min)	Numerical	(1,68-29,79)
Feels_Like_Avg	Average "feels like" temperature for the day (°F)	Numerical	(57,75-98,19)
Heat_Index	Heat index value for the day	Numerical	(65,51-96,68)
Dew_Point	Dew point temperature (°F)	Numerical	(26,26-76,65)
Humidity	Relative humidity percentage	Numerical	(11,75-92,46)

Precipitation bool	Boolean that indicates if there were precipitations	Boolean	(True-False)
Precipitation	Total precipitation for the day (inches)	Numerical	(-0.2-0.47)
Precip_Prob	Probability of precipitation (percentage)	Numerical	(-0,9-103,54)
Precip_Cover	Coverage of precipitation (percentage)	Numerical	(-1,94-25,58)
Wind_Gust	Maximum wind gust speed (mph)	Numerical	(3,5-33,52)
Wind_Speed	Average wind speed (mph)	Numerical	(4,89-19,02)
Wind_Direction	Wind direction (degrees)	Numerical	(12,55-349,84)
Pressure	Atmospheric pressure (hPa)	Numerical	(1000,45-1030,66)
Cloud_Cover	Cloud cover percentage	Numerical	(-4,40-101,58)
Visibility	Visibility distance (miles)	Numerical	(8,25-15,71)
Solar_Radiation	Solar radiation (W/m²)	Numerical	(8,03-356,27)
Solar_Energy	Solar energy received (kWh)	Numerical	(0,06-29,82)
UV_Index	UV index level	Numerical	(-0,18-10,16)
Severe_Risk	Risk level of severe weather (e.g., low, moderate, high)	Categórica	(very low, low, medium, high, very high)
Sunrise	Sunrise time	Temporal	(06:07:30-08:12:43)
Sunset	Sunset time	Temporal	(06:13,56-08:00:00)
Moon_Phase	Phase of the moon (e.g., new moon, full moon)	Categorical	(new moon, full moon, etc)
Conditions	General weather conditions (e.g., clear, cloudy)	Categorical	(clear, partially cloud, cloudy, rain and partially cloudy, overcast)

Source	Data source information	Categorical	(fcst, comb)
Severity_Score	Score representing the severity of weather conditions	Numerical	(1,58-5,16)
Day_of_Week	Day of the week of the recorded data	Categorical	(Monday, Tuesday, Wedneday, Thursday, Friday, Saturday, Sunday)
Is_Weekend	Indicator if the day is a weekend	Boolean	(True, False)
Health_Risk_Score	Score representing the potential health risk	Numerical	(8,49-11,49)

Pre-processing:

El primer pas en el nostre *pre-processing* va ser eliminar les variables irrellevants (p.ex.: icona de de condicions, descripció de les condicions, neu, estació de l'any, mes i estació on s'ha mesurat), perquè no contribueixen a afegir cap mena d'informació rellevant. A més a més, algunes d'aquestes variables presentaven molts de valors *missing*, però al eliminar-les de la nostra base de dades també ens hem tret aquest problema de damunt.

A continuació, vàrem canviar el format d'algunes variables a altres que penséssim que forin més apropiades. Per exemple, vam canviar el tipus de precipitació d'una variable categòrica a un booleà, perquè tota la precipitació era pluja. També modificàrem les variables de *moon fase* i *severe risk* de variables numèriques a categòriques, ja que vàrem considerar que així té més sentit i és més apropiat treballar-les així.

Altres canvis que férem en la nostra *database* han set canviar les unitats de mesura a unes que se'ns fan més familiars, d'unitats de mesura imperials/americanes a unitats internacionals. Alguns canvis són de Fahrenheit a Celsius, de milles per hora a quilòmetres per hora i de polzades a centímetres.

Workplan

1. **<u>Gantt diagram:</u>**

2. Division of tasks:

Participant	Mariona	Raúl	Marc	Núria	Joan
D2.Task 1: Find database	x	x	x	x	x
D2. Task 2: Analyze variables	x			x	
D2. Task 3: FInd missing data		x	x		x
D2. Task 4: Process of getting the data and content	x			x	

D2. Task 5: Metadata File	x			x	
D3. Task 6: Gantt diagram			x		
D3. Task 7: Division of tasks			x		
D3. Task 8: Risk contingency plan			x		
D4. Task 9: Preprocessin g	x	x	x	x	x
D4. Task 10: Univariate descriptive statistics	x		x		x
D4. Task 11: Bivariate descriptive statistics		x		x	
D4. Task 12: Generalized Linear Models	x	x	x		
D4. Task 13: Time series				x	x
D5. Task 14: PCA analysis for numerical variables	x			x	
D5. Task 15: Hierarchical CLustering on original data		x	x		x
D5. Task 16: Partitional Clustering	x	x	x		

D5. Task 17: Profiling of clusters				x	x
D5. Task 18: Discussion and conclusions	x	x	x	x	x
D6. Task 19: Final Gantt and risks			x		

3. **<u>Risk contingency plan</u>**

Risk	**How to prevent**	**How to manage**
A member of the group leaves the course.	Make sure that all the tasks are realized by more than one person.	Reallocate the tasks that have been damaged.
Too much missing data.	Choosing a database with a low percentage of missing data.	Minimizing the impact of the missing data using statistical methods and preprocessing.
Graphics don't give enough information.	Pick a clear database with manageable structures.	Using appropriate tools to make the most of it.
Too few usable variables.	Ensure that the variables of the database are significant.	Try to change the perspective of the plan in a way that the variables are important.

Objectives

Com a objectius tenim que estudiar les diferentes variables i com interactuen entre elles (si són independents, dependents, estatistiques univariants i bivariants) i així utilitzar diferents estadístics per a estudiar el comportament d'aquestes, com la recta de regressió lineal i així veure les tendències de les variables entre elles.

2. Initial Statistics Analisis

2.1 Preprocessing

El primer pas per preprocessar les dades va ser eliminar les variables irrellevants (per exemple, icona de condicions, descripció de condicions, neu, temporada, mes, estacions), perquè no aportaven informació nova o no estaven ben explicades. Algunes d'aquestes variables tenien molts missing values, però després d'eliminar-les de la nostra base de dades ja no n'hi havia més.

Després vem canviar el format d'algunes de les variables per una altra que hem cregut més adient. Vam canviar el tipus de precipitació d'una variable categòrica a una booleana, perquè tota la precipitació era pluja (no hi havia cap observació de neu, calamarsa, etc.). També vam modificar la variable de la fase lunar i el Severe Risk de variables numèriques a categòriques perquè creiem que eren més adequades i fàcils d'entendre.

Alguns altres canvis que hem fet a la nostra base de dades són canviar les unitats de mesura per les que estàvem més familiaritzats (Farenheit a Celcius, milles per hora a quilòmetres per hora, polzades a centímetres, etc.)

2.2 Descriptive Statistics

Univariate statistics

Les variables de temperatura (temp_max, temp_average, temp_min) segueixen un patró molt homogeni en la seva distribució. I totes aquestes són dependents entre si, així que tenen una distribució casi igual.

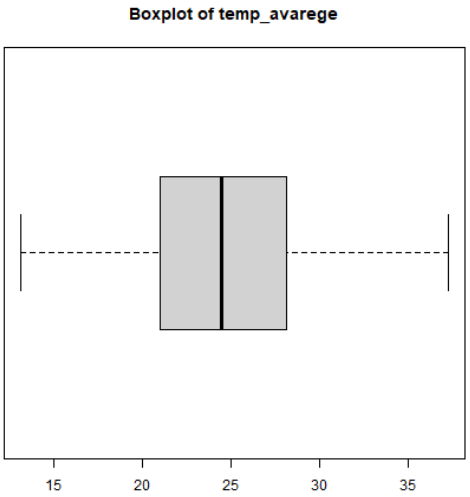

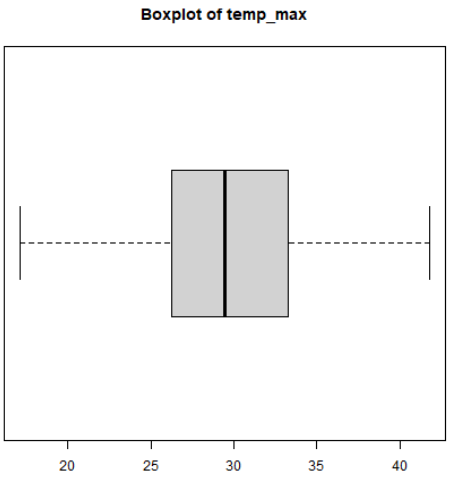

En el barplot de conditions es pot veure que la majoria de dies presenten un temps sense núvols ("Clear") o un poc nevolat ("Partially cloudy"), mentres que hi ha pocs

dies molt nevolats (“Overcast”) i de pluja amb un poc de núvols (“Rain, Partially cloudy”).

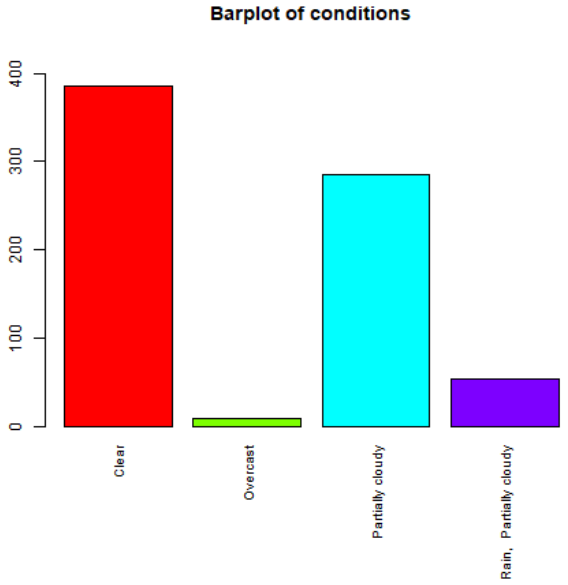

Veient els gràfics de precipitacions, es pot afirmar que la majoria de dies no hi ha precipitacions, cosa que decanta la mediana dels gràfics a valors baixos, mentres hi han molts de valors per damunt del tercer quartil. Això és degut per al caràcter també booleà que té la precipitació.

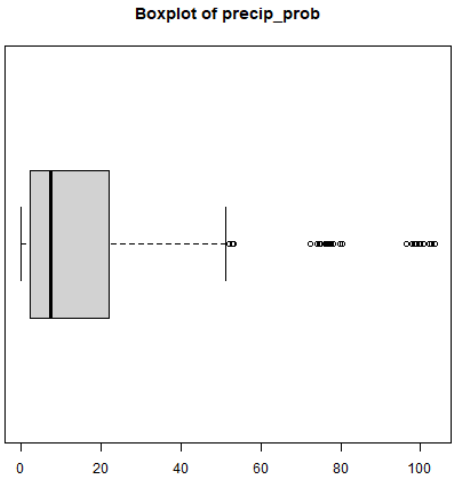

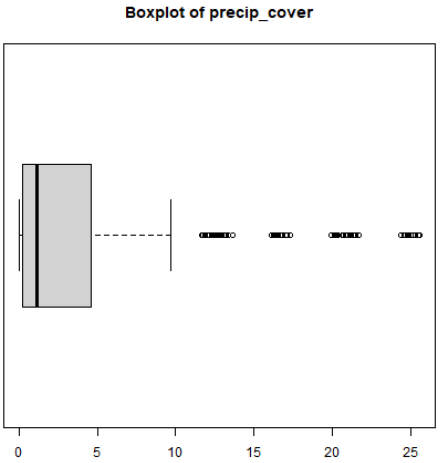

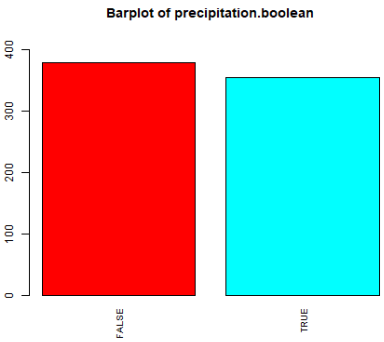

Llavor podem veure com la variable Severe_risk té casi tots els seus valors en Low i un poc en Moderate, així que podem afirmar que la majoria de dies hi ha poc risc ambiental. A més del boxplot de Severity_score on es pot veure que la mediana tendeix a valors baixos, degut que la majoria de dies són “Low” i Severe_risk depén de Severity_score.

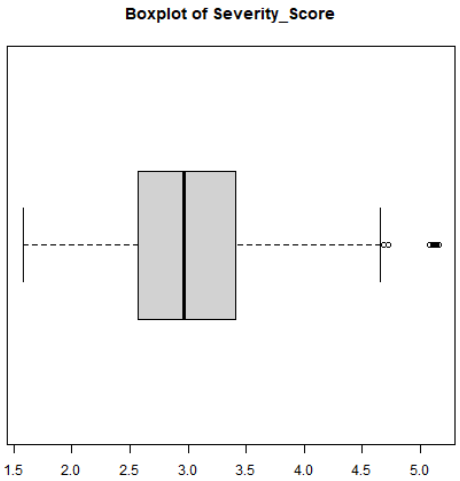

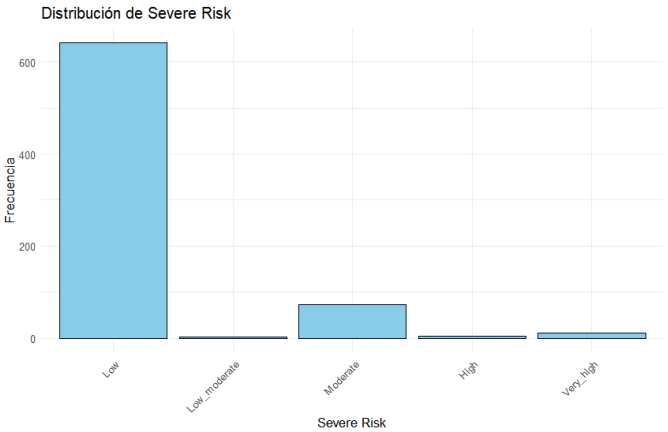

En la humitat, podem veure que la media de l’aire es troba entorn al 60%, encara que hi ha molt de valors per baix del primer quartil.

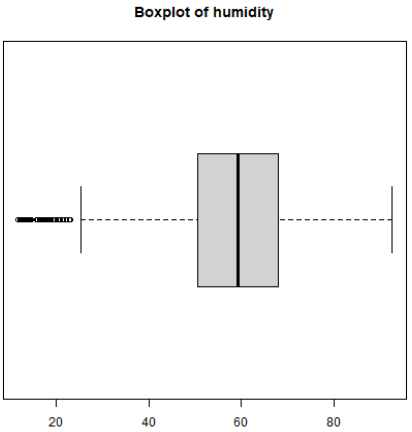

La pressió és una variable que tendeix a una distribució normal dintre de la nostra base de dades, tot i que amb valors concentrats entre els 1007 i 1020 hPa de pressió.

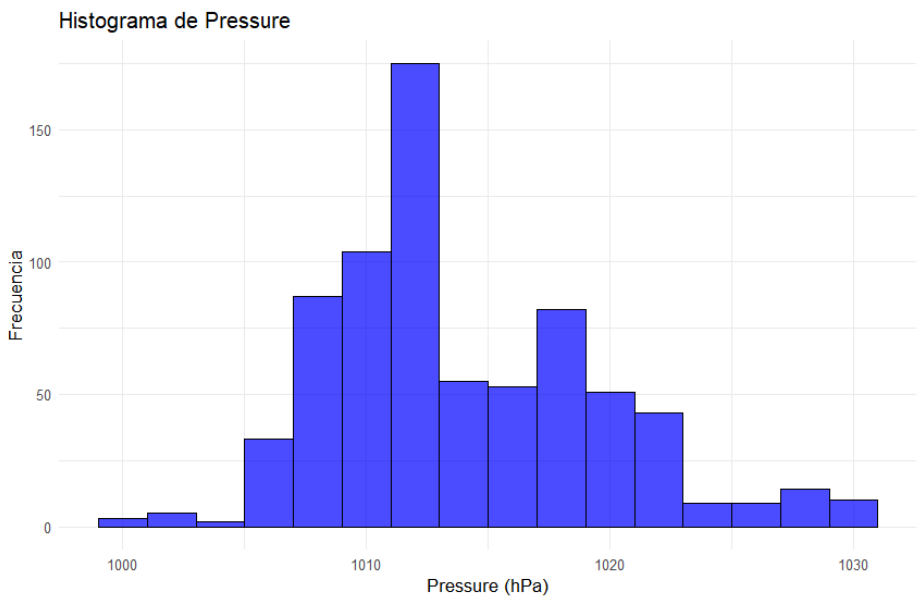

En aquest altre gràfic també podem veure que el wind_speed també tendeix a una distribució normal, a més que en general no és gaire ventós.

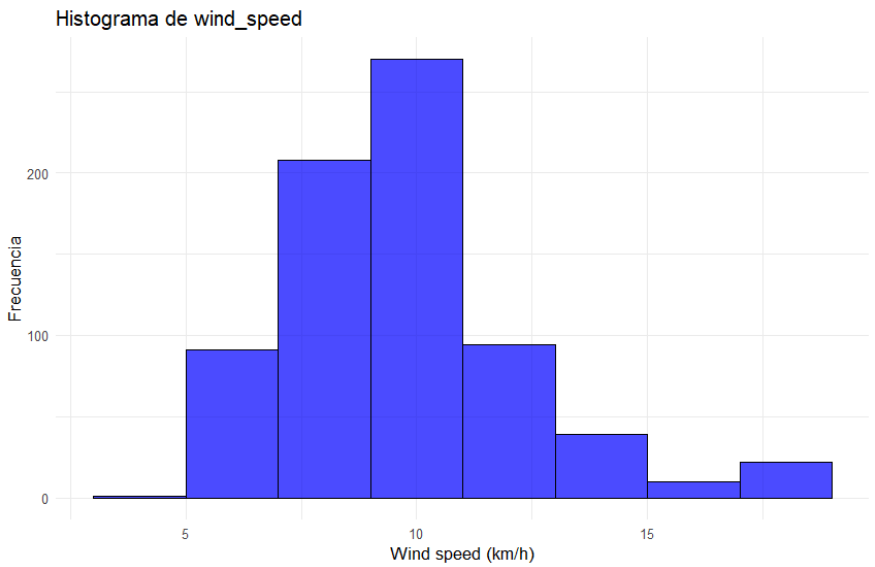

Bivariant

Dos variables interessants per a estudiar entre sí són la temperatura promig i la humitat, ja que per raons humanes podriem concloure que quan més temperatura fa més temperatura fa. Però en aquest cas observem el contrari, en les observacions es concentra més les humitats altes en les temperatures baixes, això podria ser pel fet que feim observacions en ciutats diferents. A més hi ha una gran concentració d'observacions al mig que representarien les temperatures cap als 23ºC i el 60% d'humitat.

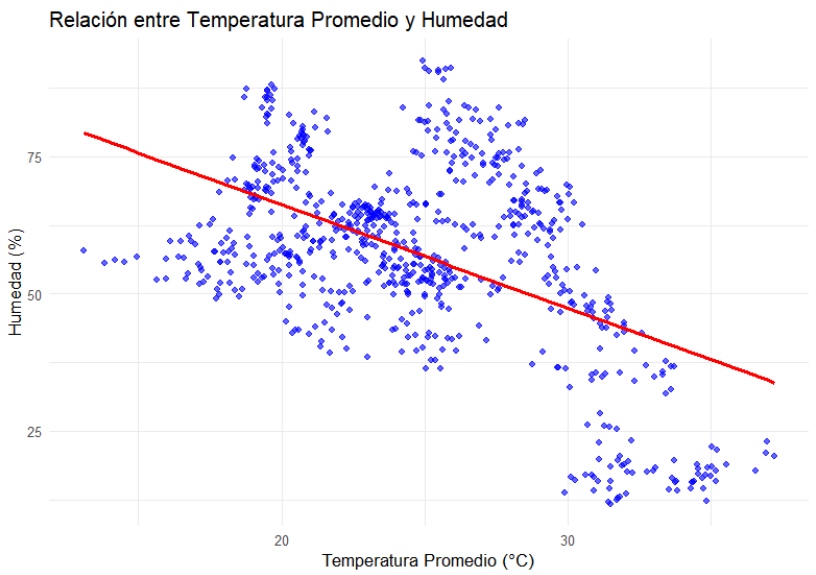

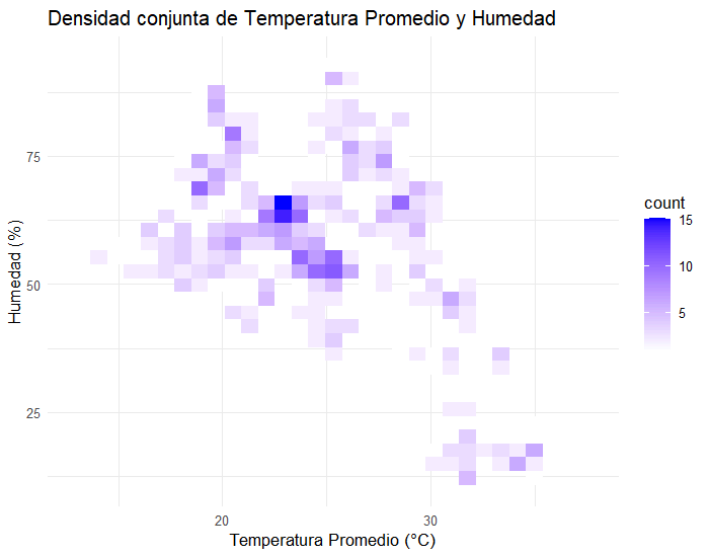

Podem observar una clara relació entre l'índex UV i la cobertura de núvols, pel fet que en altes cobertures de núvols hi ha molt menys de rajos UV que quan hi ha poca cobertura, com es pot observar en la recta de regressió generada automàticament per R.

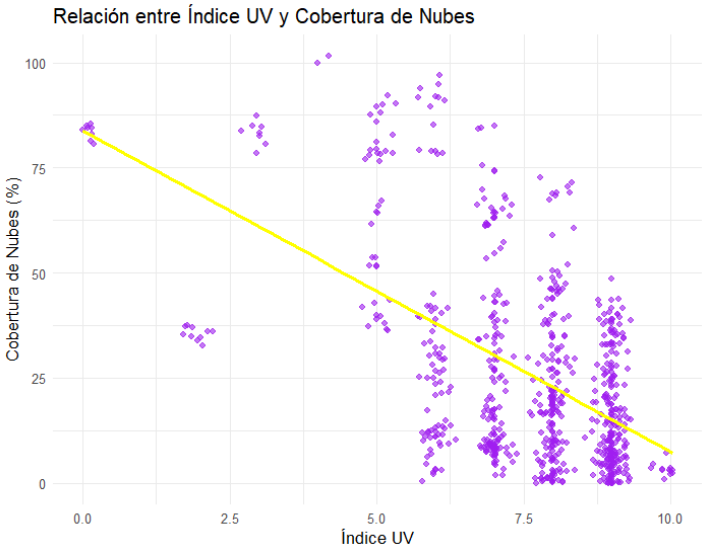

Entre la Temperatura promig i la puntuació de severitat trobem una relació positiva entre elles. És a dir, que en temperatures elevades existeix un perill major.

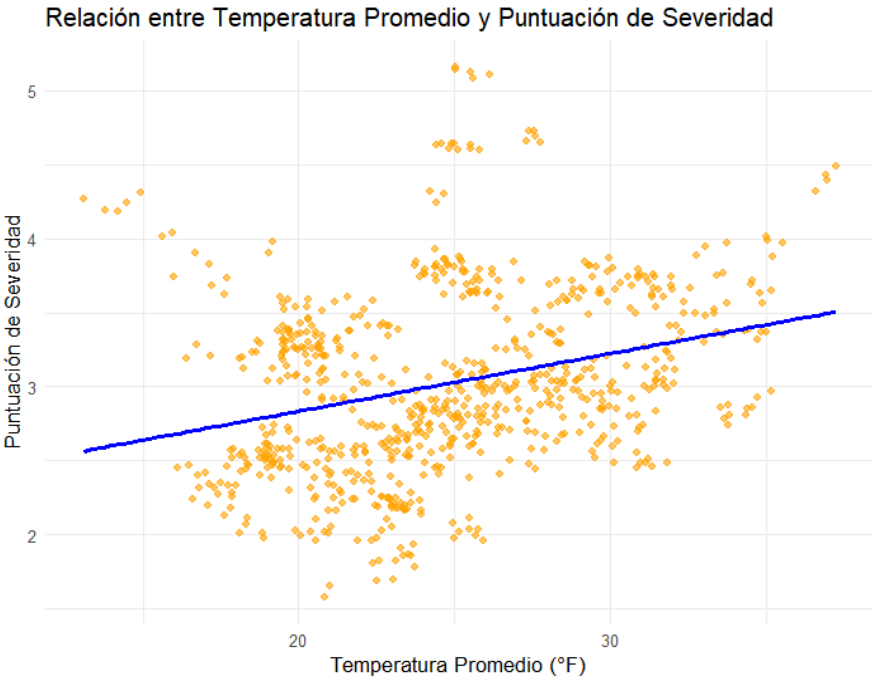

3. Generalized Linear Models (GLMz)

3.1 Numerical Response

En aquesta secció, hem ajustat un model lineal generalitzat amb l'objectiu de predir una variable contínua, Severity_Score. L'elecció d'aquesta variable es va basar en la naturalesa del nostre conjunt de dades, que conté informació sobre fenòmens atmosfèrics. Aquestes variables suggereixen que Severity_Score és una opció lògica i coherent per explorar els patrons en les dades.

Abans de començar a ajustar el model, va ser essencial determinar la distribució de les dades. Per a això, vam analitzar diverses distribucions per identificar quina s'adaptava millor al nostre conjunt de dades. En particular, no estàvem segurs de si la família normal o la gamma seria més adequada per modelar Severity_Score. Tot i que les dades semblaven seguir una distribució Gaussiana, vam decidir no descartar la distribució gamma. Per tant, vam provar les dues distribucions, avaluant com es comportaven en termes d'ajustament i quin impacte tenien en la interpretació dels resultats.

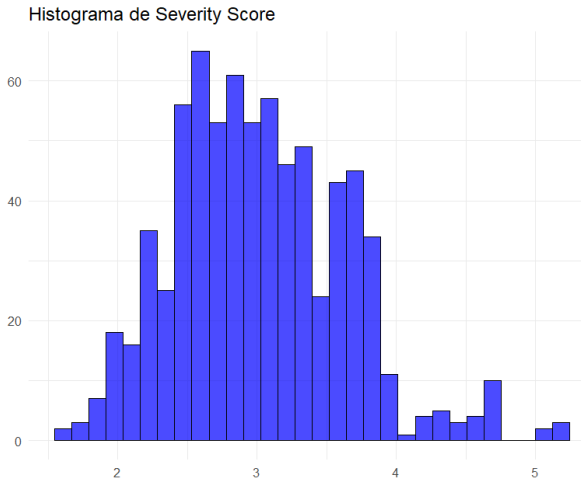

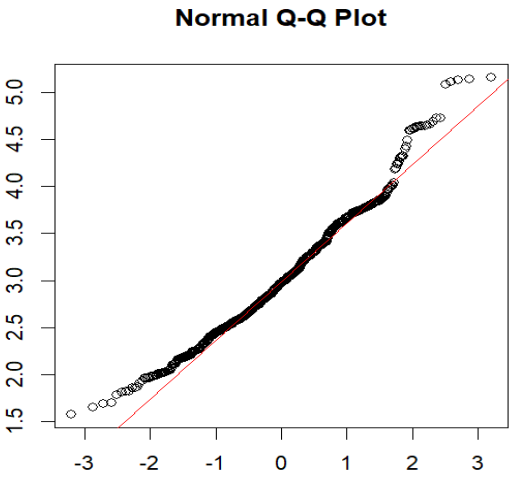


```
> summary(dd$Severity_Score)
   Min. 1st Qu.  Median    Mean 3rd Qu.    Max.
   1.58    2.57    2.97    3.02    3.41    5.16
```

Per dur a terme aquest anàlisi, vam utilitzar R per construir un model que inclogués totes les variables disponibles al conjunt de dades. Això ens va permetre avaluar la rellevància i l'impacte de cada variable en la predicció de la variable Severity_Score, identificant quines eren significatives segons el seu p-valor per al model final. A

partir d'aquest anàlisi, va ser possible determinar quines variables aporten informació útil i haurien de ser considerades en un model ben ajustat i precís.

Les variables més rellevants són: Heat_Index, humitat, precipitació, ràfegues de vent, índex UV i Health_Risk_Score.

Un cop identificades les variables rellevants per a la predicció de la variable Severity_Score, vam ajustar un model lineal generalitzat utilitzant aquestes variables. Per assegurar un anàlisi complet, vam decidir provar les dues famílies de distribucions (la normal i la gamma). En tots dos casos, vam construir models utilitzant només les variables que havien demostrat ser significatives. Això ens va permetre comparar com es comportaven les diferents distribucions en termes d'ajustament i precisió, avaluant quina proporcionava millors resultats en la predicció de Severity_Score. Observant l'AIC de cada model vam observar que el del model gaussià era més baix i, per tant, aquest és més ajustat i simplificat.

Un cop generat el model obtenim la fórmula del model amb els coeficients estimats:

$$\text{Severity_Score} = 0.1521 - 0.0087\times\text{Heat_Index} - 0.0029\times\text{humidity} + 0.0914\times\text{precipitation} + 0.0943\times\text{wind_gust} + 0.1854\times\text{uv_index} + 0.0937\times\text{Health_Risk_Score}$$

La fórmula ens indica l'efecte que té cada variable al Severity Score. Observem que l'intercepte és de 0.1521. Això vol dir que quan totes les variables predictores són zero el Severity Score té un valor de 0.1521. La resta de valors són els coeficients de les variables predictores i reflecteixen com cada variable influeix en la predicció: per cada unitat incrementada del Heat Index el Severity Score disminueix 0.0087 unitats, i així per cada variable amb el seu coeficient respectiu. Observem que les variables precipitation, wind_gust, uv_index i Health_Risk_Score tenen un impacte positiu en el Severity Score, és a dir, fan que incrementi; en canvi, les variables Heat_Index i humidity tenen un impacte negatiu, fan que disminueixi.

<u>Validació</u>

La validació del model la vam realitzar analitzant els gràfics obtinguts. Es pot apreciar un bon ajust del model i com aquest s'adapta correctament als patrons presents a les dades

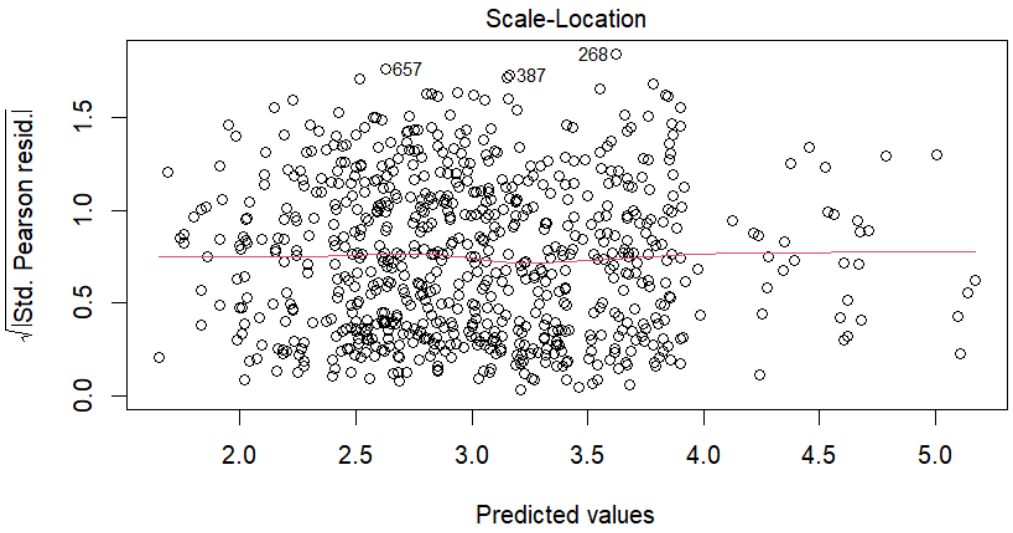

Aquest gràfic avalua la homoscedasticitat del model, és a dir, que tingui una variància constant. A l'eix X es mostren els valors predits, i a l'eix Y l'arrel dels residus estandarditzats. Com observem, els punts estan distribuïts aleatòriament al voltant de la línia vermella horitzontal sense patrons clars verificant la homoscedasticitat del nostre model.

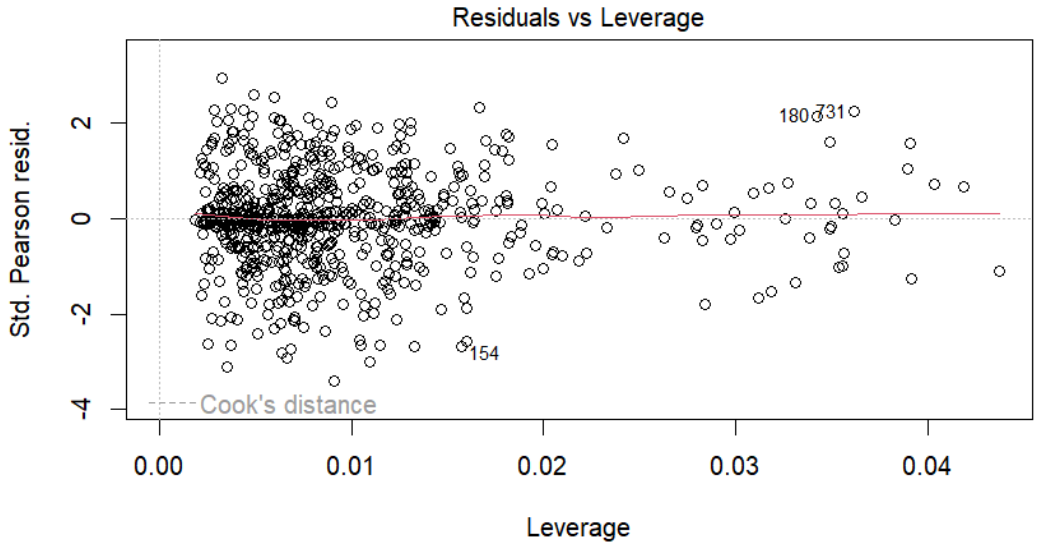

El Residuals vs Leverage identifica valors influents en el model. L'eix X mostra la leva (leverage) de les observacions. Els valors més a la dreta tenen una leva més alta, és a dir, tenen un pes més gran en el càlcul del model. L'eix Y mostren els residus estandarditzats, la diferència entre els valors observats i els valors predits. No observem cap valor fora del normal ni cap punt fora de les línies de Cook.

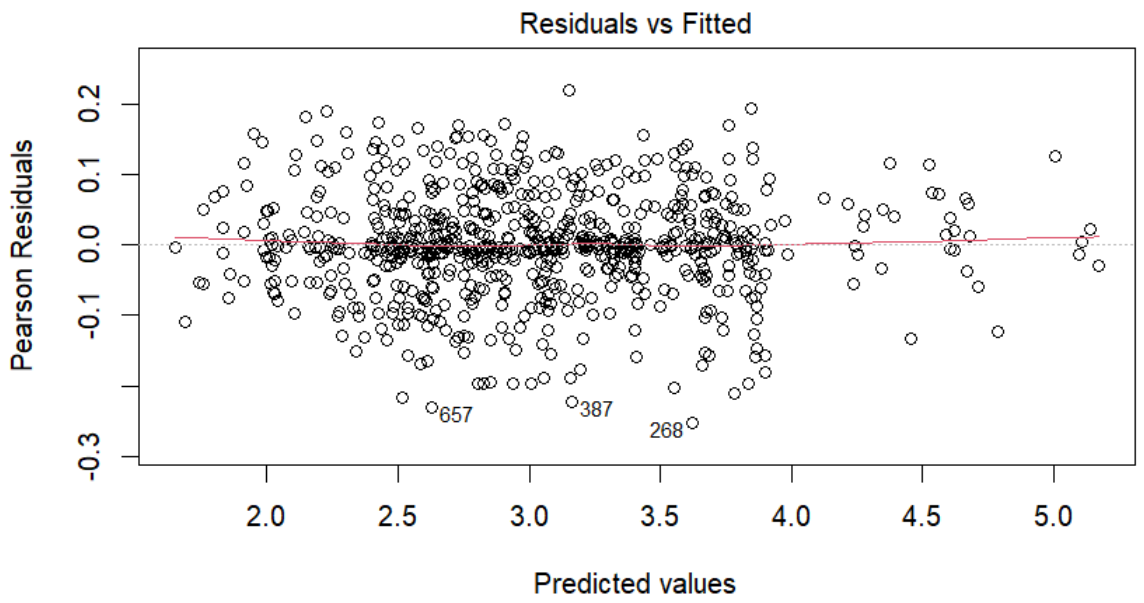

El Residual vs Fitted mostra els residus enfront dels valors ajustats. Veim que els residus a l'eix Y estan distribuïts aleatòriament al voltant de la línia horitzontal (residu = 0) sense un patró clar, indicant que el model s'ajusta bé.

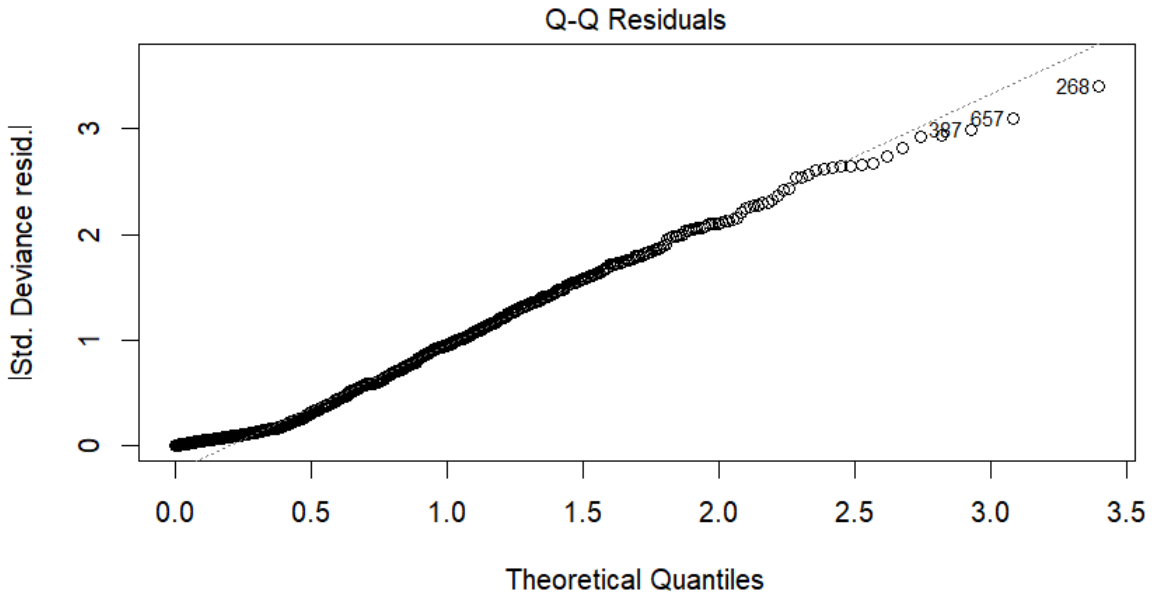

L'últim gràfic avalua la normalitat dels residus. A l'eix X hi ha els quartils teòrics, i a l'eix Y els residus estandarditzats. Els punts segueixen aproximadament la línia diagonal això indica que els residus segueixen una distribució normal.

A més vam voler comprobar si el model veritablement era capaç de predir dades veritables. Per això vam entrenar el model amb el 70% de les observacions de la

nostra base de dades i amb aquest vam predir el 30% de dades restant. Comparem els primers valors per tenir una idea de la precisió de la predicció:

```
1        2        3        4        5        6
3.380617 3.362981 3.055559 2.769982 3.190163 3.263137   valors reals
3.37     3.37     3.05     2.74     3.19     3.26       valors predits
```

Només mirant els primers 6 valors sembla que és una molt bona predicció ja que els valors predits son molt semblants als reals. Per comprovar que realment funciona amb totes les prediccions fem un gràfic comparant els dos.

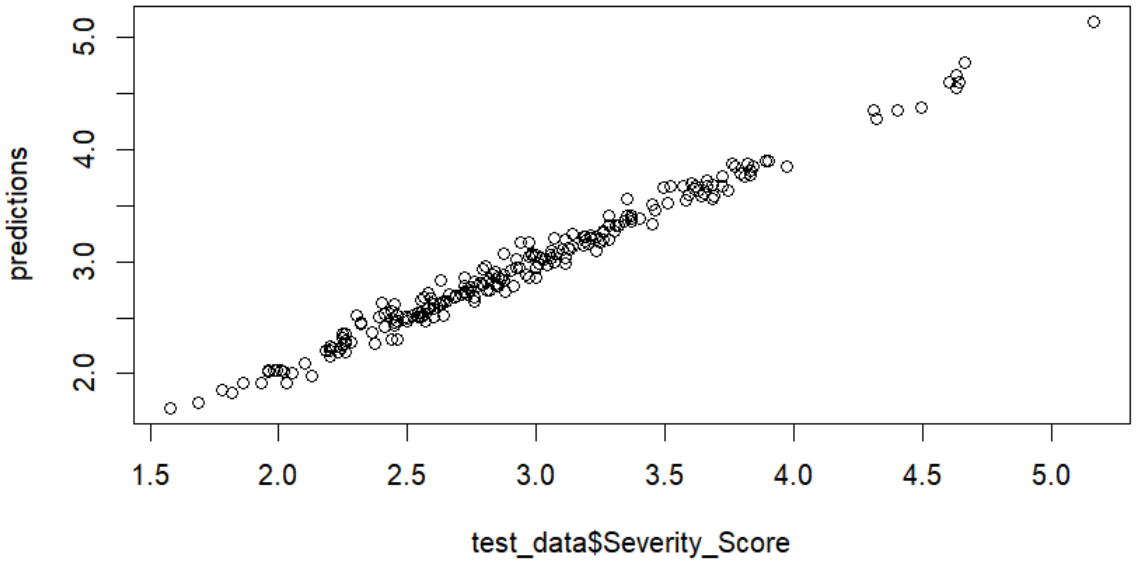

Al fer el gràfic de les dades predites i les veritables dades del model es veu que la predicció és molt bona i fiable ja que proporciona estimacions quasi exactes.

★ Millores realitzades

Com a millora pel nostre model hem fet que les nostres prediccions puguin fer-se per dies futurs, ja que el model que teniem podia predir el valor de la variable severity score amb els valors de la resta de factors ja donats. Hem afegit un *lag*, és a dir, un retard en les dades per aconseguir que el nostre model sigui capaç de predir el valor de la variable severity score amb anterioritat.

3.2 Binary Response

Per la binary response, voliem predir la variable booleana precipitation que en altres paraules indica si plou o no. Per això, hem volgut ajustar un model logístic amb funció d'enllaç sigmoid, per fer un model probabilístic amb distribució binomial.

En intentar seleccionar les variables predictores, vam fer una matriu de correlació per veure quins valors podien tenir més rellevància per predir la precipitació. Com que, llevat de dos o tres factors, això no ens dèia cap cosa, ens vam deixar guiar per sentit comú i vam anar provant amb els factors que creiessim més rellevants, però no vam tenir gaire èxit, doncs el model era poc millor que aleatori.

Per capturar l'efecte de les variables meteorològiques dels dies anteriors, vam crear variables retardades per a cada variable meteorològica rellevant:

- **Lag 1, Lag 2 i Lag 3**: Vam afegir noves columnes per representar les variables meteorològiques dels 1r, 2n i 3r dia anterior per a cada ciutat.
- A més de les variables meteorològiques retardades, vam crear interaccions entre algunes variables com la temperatura i el punt de rosada (`temp_dew_interaction`).

A més, com a millora respecte a l'anterior, vam crear dues noves variables temporals:

- **`month`**: El mes en què es va enregistrar la dada.
- **`day_of_year`**: El dia de l'any, que permet tractar la temporalitat de manera contínua.

Vam intentar implementar també la Latitud i Longitud, però ens van crear molts problemes i no va acabar al model final.

Per fer selecció de variables i regularització al mateix temps, entrenem el model amb Elastic Net, que fa servir una barreja de regularització LASSO (L1) i RIDGE (L2) per reduir els coeficients irrellevants. La part L1 en redueix una gran majoria

(depenent de l'hiperparàmetre lambda) a zero, fent selecció de factors implícita, i la L2 redueix i iguala els coeficients de variables correlacionades. Per tant, en fer una barreja dels dos tipus de regularització, podem agafar varies variables correlacionades en comptes d'agafar-ne només una del grup de correlacionades, com ocorreria en cas de fer servir L1 únicament.

Com que al principi vam notar que el model era molt millor predint dies de pluja conseqüents a altres dies de pluja i se n'aprofitava d'això, vam posar ponderacions a les observacions per donar més importància a aquells dies on no hi hagués plogut ni el dia anterior ni dos dies abans (amb ponderacions de 5, 3, i 1 per a dies amb dos dies sense pluja, un i cap, respectivament).

Vam crear una matriu de model (`model.matrix()`) que inclou totes les variables explicatives (features) necessàries per ajustar el model, i posteriorment ajustem un model de regressió logística regularitzat. Aquesta funció aplica grid search amb validació creuada (5 fold cross validation) per trobar el valor òptim de lambda i alpha (el percentatge de cada tipus de regularització).

Un cop fet això, fem la validació amb el set de test (vam fer una separació 70/30).

Segons el rang de paràmetres de lambda que feiem servir a la regularització obteniem diferents tipus de models. La gran majoria eren altament simplistes, fent servir només dues variables: pluja ahir i abans d'ahir. En reduir la regularització ja obtenim models més complexos, però el rendiment apenes millora un en un 2%.

En general seria lògic pensar que ens interessa més la corba PR que la ROC pel fet què la freqüència de pluja sol ser petita. Tot i això, al nostre dataset les freqüències eren relativament semblants amb una distribució més o menys igual per tant ens convé més veure el trade off entre la TP i FP.

Els resultats son els següents:

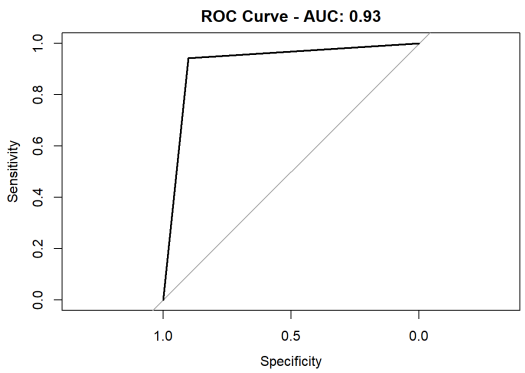

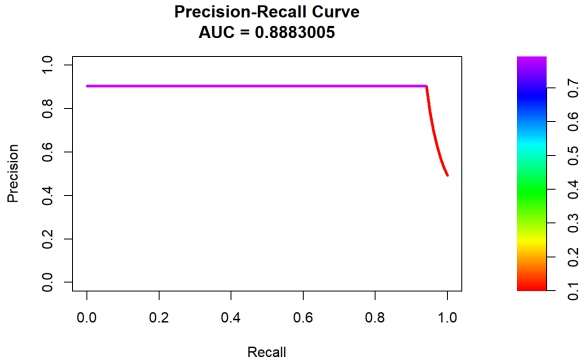

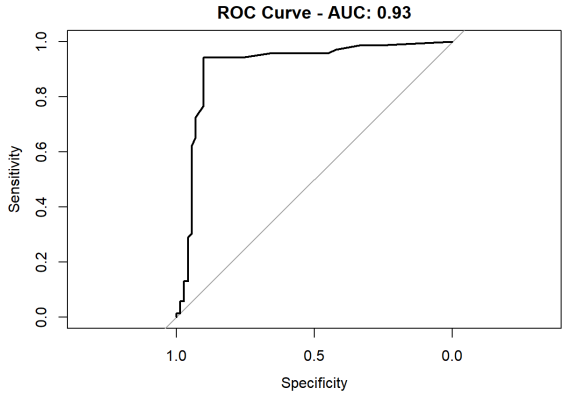

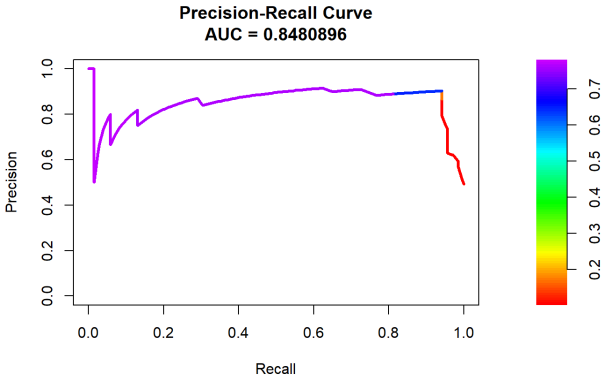

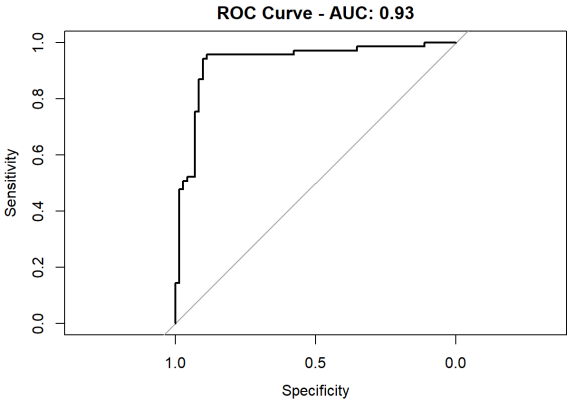

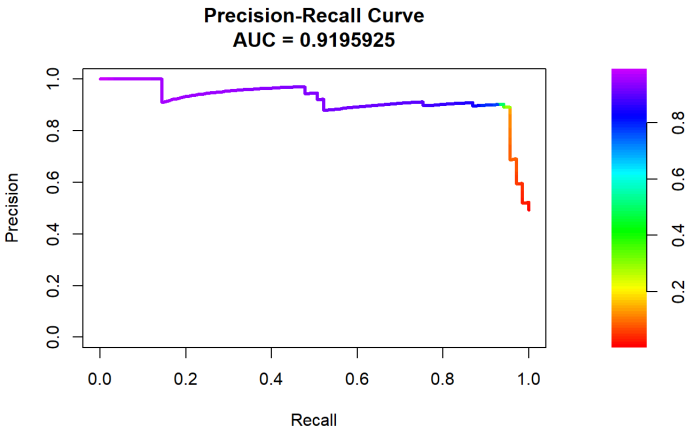

Com es pot observar, les dues rectes del model senzill es poden dividir en dos seccions. Això es deu a que el model basa les seves decisions en tan sols una variable predictora. Tot i això, sembla funcionar bé i hem fet molt anàlisi per evitar overfitting, i ens dona resultats superiors a qualsevol altre mètode que hagim provat.

El següent model inclou també el booleà de precipitació, no només el valor continu, per tant sumen 4 variables.

En reduir la regularització a l'últim model, aconseguim pujar la precisió i accuracy un tres percent, però a costa d'introduir 18 noves variables al model. Si aquest petit increment al rendiment val la pena o no, això ja depèn si valorem més interpretabilitat o precisió.

Aquí tenim la matriu de confusió del model simple:

```
Confusion Matrix and Statistics

          Reference
Prediction FALSE TRUE
     FALSE    64    4
     TRUE      7   65

               Accuracy : 0.9214
                 95% CI : (0.8638, 0.9601)
    No Information Rate : 0.5071
    P-Value [Acc > NIR] : <2e-16

                  Kappa : 0.8429

 Mcnemar's Test P-Value : 0.5465

            Sensitivity : 0.9014
            Specificity : 0.9420
         Pos Pred Value : 0.9412
         Neg Pred Value : 0.9028
             Prevalence : 0.5071
         Detection Rate : 0.4571
   Detection Prevalence : 0.4857
      Balanced Accuracy : 0.9217

       'Positive' Class : FALSE
```

Conclusions

En provar varis mètodes de regularització, tots es decanten només per dues variables principalment: pluja ahir i pluja abans d'ahir. I, com hem vist, només amb la quantitat de pluja del dia anterior en tenim suficient. Amb això, donat el gran rendiment del model, podem treure la conclusió de que no cal gaire informació per fer una predicció educada sobre si plourà o no al dia següent, donat el context de l'època de l'any i les ciutats dels Estats Units.

Això ens fa pensar que un model com un arbre de decisió seria molt més adequat per la tasca.

Apèndix

Al principi vam provar una implementació algorísmica de selecció de factors completament diferent, backward selection, encaixant un model un model amb totes les variables que poguessin tenir ni que fos un mínim de rellevància i deixant l'algorisme treure factors segons com canviï l'AIC del model reduït. Amb això, vam acabar amb els següents predictors:

dew_point	**yes**
pressure	**yes**
temp_avg	
temp_min	
severity	
pressure	
visibility	
wind_gust	**yes**
source	
sunrise	
sunset	**yes**
temp_rang	**yes**
city	**yes**

I un model amb els coeficients següents:

```
Coefficients:
                      Estimate Std. Error z value Pr(>|z|)
(Intercept)          161.35891   46.16146   3.496 0.000473 ***
dew_point              0.04512    0.02534   1.781 0.074965 .
pressure              -0.15575    0.04436  -3.511 0.000446 ***
wind_gust             -0.13515    0.02730  -4.951 7.37e-07 ***
Sunset_catLate        -0.57501    0.36173  -1.590 0.111922
Sunset_catVery Early  -1.02146    0.82323  -1.241 0.214686
Sunset_catVery Late    0.42106    0.66767   0.631 0.528276
Temp_Range            -0.17280    0.04160  -4.154 3.27e-05 ***
CityDallas            -0.70422    0.60847  -1.157 0.247121
CityHouston           -0.08882    0.64885  -0.137 0.891122
CityLos Angeles       -2.80034    0.63271  -4.426 9.60e-06 ***
CityNew York City     -0.70840    0.45138  -1.569 0.116555
CityPhiladelphia       0.80138    0.48565   1.650 0.098923 .
CityPhoenix           -1.00749    0.73902  -1.363 0.172792
CitySan Antonio       -0.22900    0.78271  -0.293 0.769848
CitySan Diego         -4.60987    0.79897  -5.770 7.94e-09 ***
CitySan Jose         -17.89779  698.11676  -0.026 0.979547
```

Una cosa a mencionar és que aquí no haviem afegit LAGs, per tant el model no és gaire predictor. Hi han algunes variables que no semblen gaire informatives, però la raó de tot plegat es deu a que el model tracta les variables categòriques com a conjunt de binaries, i algunes de les opcions d'aquestes no tenen gairebé rellevància (per exemple, saber que la mesura es va fer a una ciutat on l'estimació de pluja no és gaire diferent a la del model base no ens dirà molt sobre si plourà o no, comparat amb la suma dels atres coeficients.

Vam fer un split 70/30 de les dades per entrenament i prova, i vam aconseguir una accuracy del 76% i els següents resultats:

```
    Null deviance: 711.24  on 513  degrees of freedom
Residual deviance: 516.23  on 497  degrees of freedom
AIC: 550.23

Number of Fisher Scoring iterations: 16
```

```
         Actual
Predicted FALSE TRUE
    FALSE    88   31
    TRUE     22   80
```

I la Receiving Operator Curve:

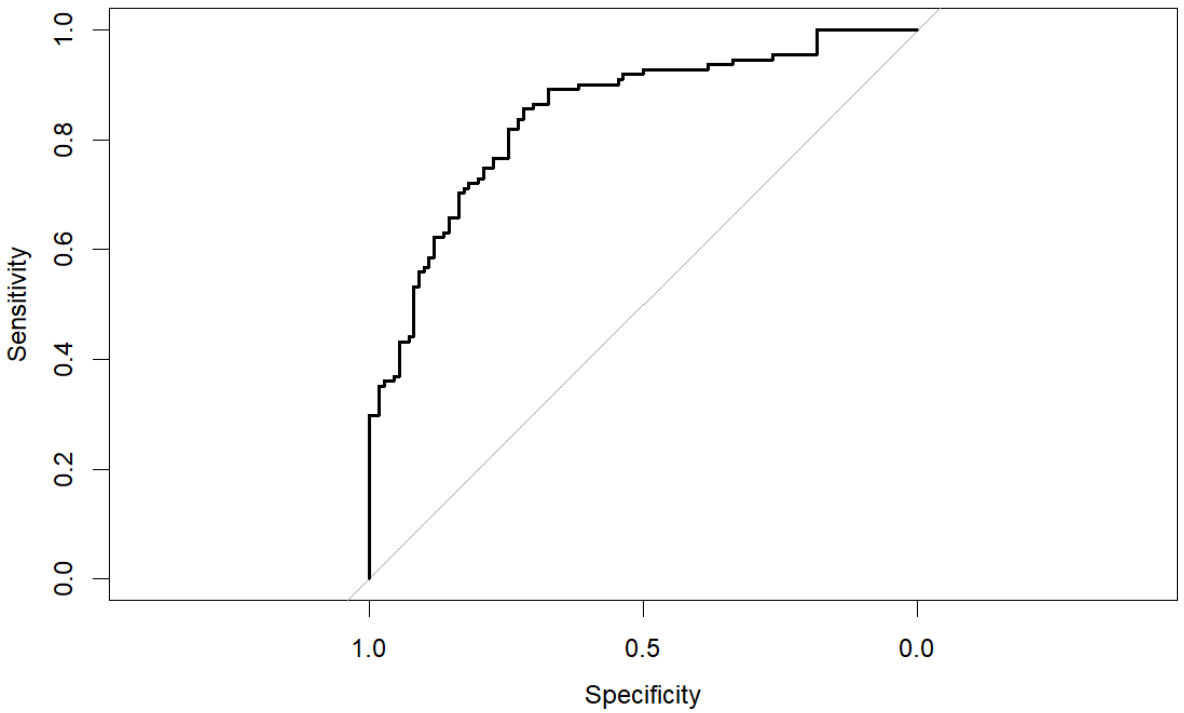

Amb un àrea sota la curva del 0,845.

Aquest model és més complex que el nou, i fins i tot amb els lags inclosos té un pitjor rendiment, per tant vam descartar la perspectiva de fer servir l'AIC per la selecció de variable, donat que tot i que fos un mètode efectiu, la regularització ha demostrat tenir un rendiment superior.

4. Time Series

- Preprocessing

Com que la nostra base de dades original no era adient per poder fer-la servir per analitzar una sèrie temporal (les observacions són únicament de vint dies), vam haver de triar una altra.

Aquesta constava d'unes 60.000 observacions, cadascuna amb la mesura dels diferents components ambientals a una hora del dia concreta. Com hi havia tantíssimes dades i també faltaven molts valors que estaven distribuïts de forma dispersa, vam decidir que treballaríem a partir de certes simplificacions i transformacions de la base de dades original.
Per tal de minimitzar la quantitat de dades i poder resoldre els "missing values" de forma eficient vam decidir utilitzar la mitjana mensual dels valors de les mesures d'un únic component atmosfèric.

En aquest apartat s'analitza la sèrie temporal de la concentració mitjana mensual de CO utilitzant tècniques de models ARMA. L'objectiu és ajustar un model adequat per capturar l'estructura temporal de la sèrie, avaluant la seva estacionarietat i aplicant transformacions quan sigui necessari.

1. **Lectura i Preprocessament de les Dades**
   Comencem l'anàlisi carregant les dades de CO i estructurant-les en una sèrie temporal amb una freqüència mensual. Després, es dibuixa la sèrie temporal per obtenir una visualització inicial del seu comportament al llarg del temps.

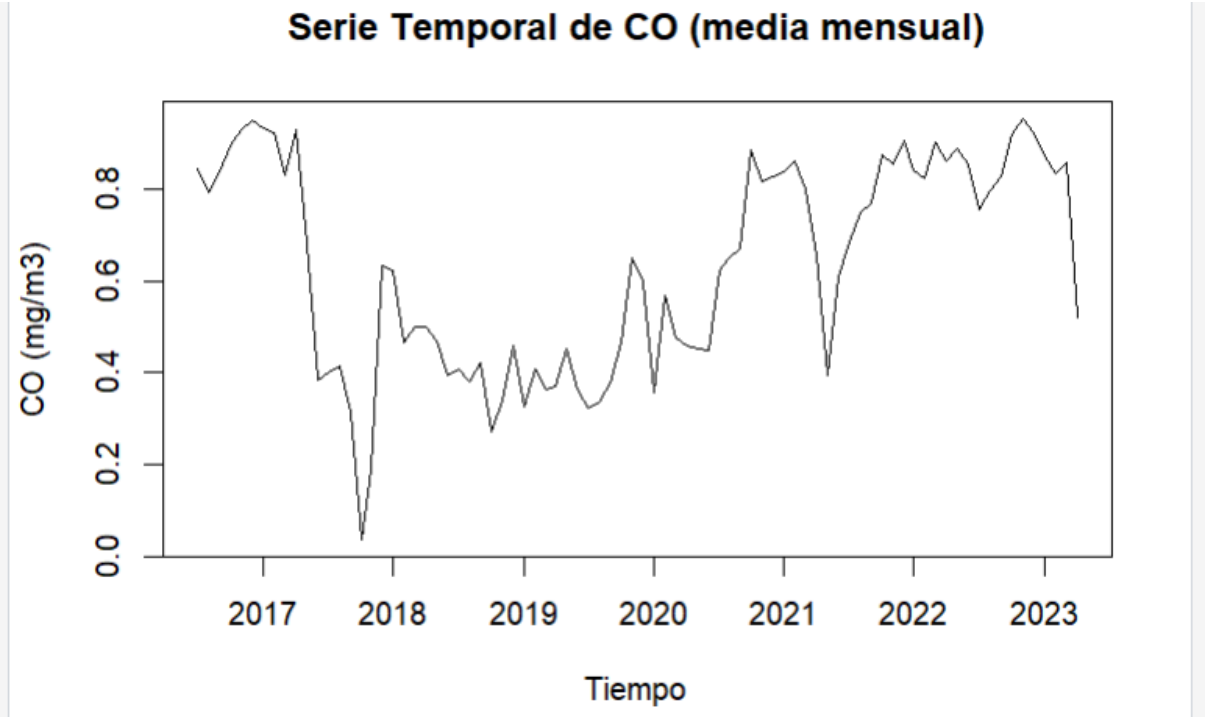

   En aquesta gràfica es poden observar fluctuacions mensuals amb caigudes significatives en certs punts. Això suggereix la presència d'estacionalitat i tendències en les dades, fet que requereix verificar si la sèrie és estacionària.

2. **Prova d'Estacionarietat: Prova ACF i PACF**
   Fem la prova de la funció d'autocorrelació(ACF) i la funció parcial d'autocorrelació(PACF) i dona els següent gràfics:

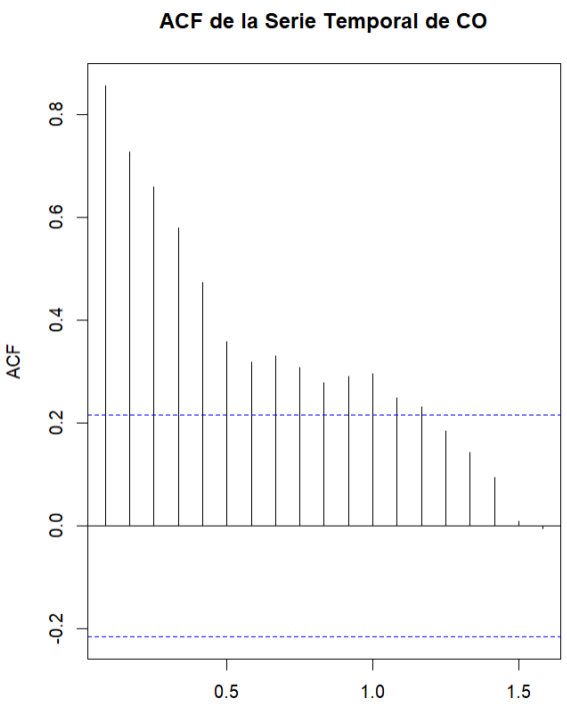

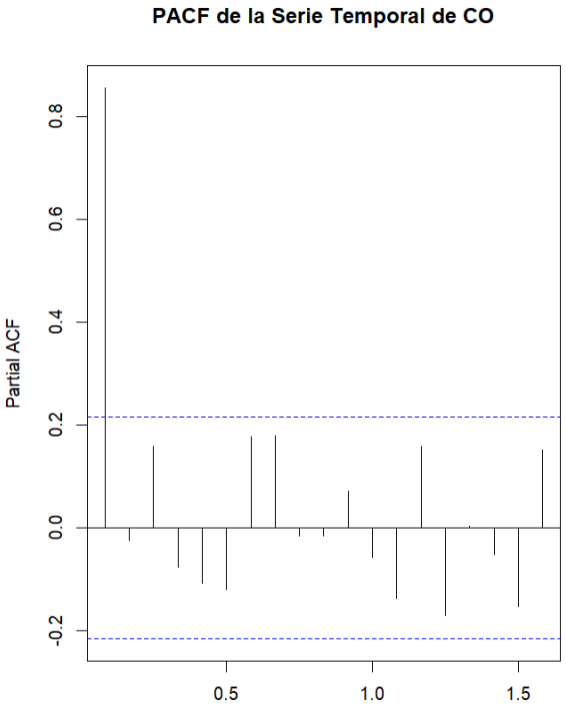

Això indica que la sèrie no és estacionària i, per tant, necessitem aplicar transformacions per aconseguir que sigui estacionària.

3. Transformacions: Logaritme i Diferenciació

Com que la sèrie no és estacionària, s'apliquen les següents transformacions:

1. **Transformació logarítmica** per estabilitzar la variància.
2. **Diferenciació d'ordre 12** per eliminar l'estacionalitat.
3. **Diferenciació d'ordre 1** per eliminar la tendència.

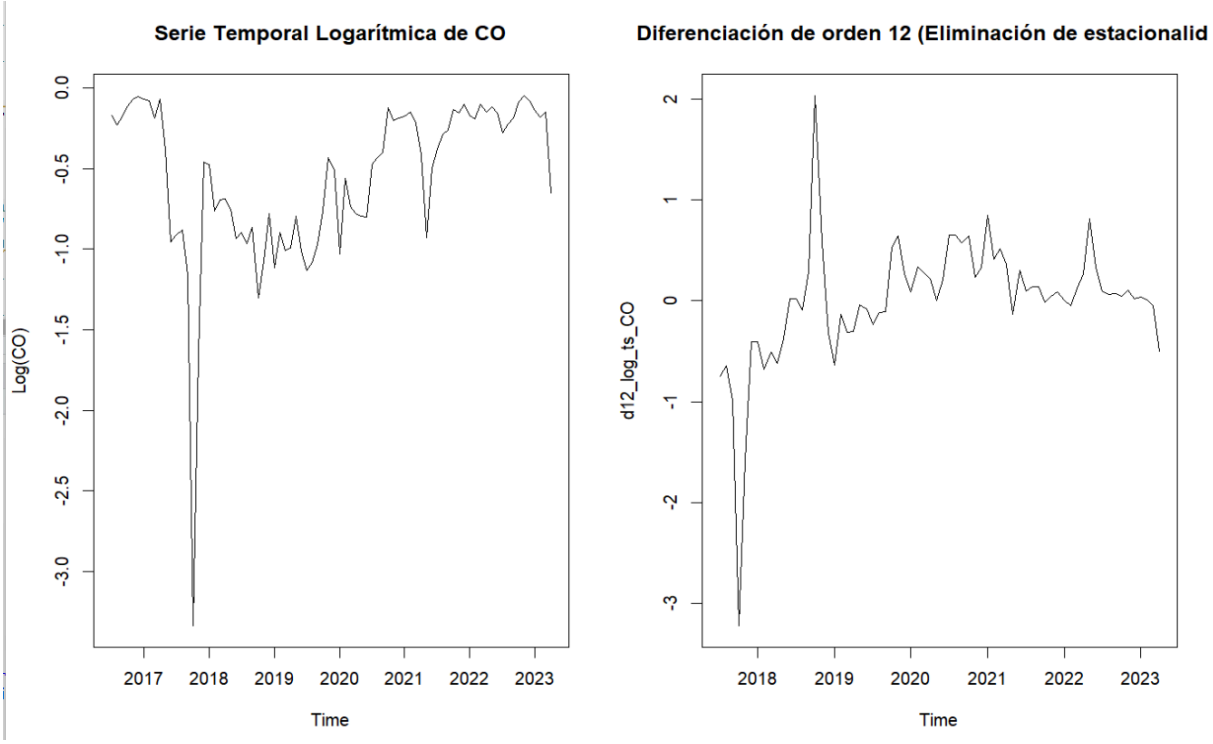
Serie Temporal Logarítmica de CO
Log(CO)
0.0
-0.5
-1.0
-1.5
-2.0
-2.5
-3.0
2017
2018
2019
2020
2021
2022
2023
Time
Diferenciación de orden 12 (Eliminación de estacionalid
d12_log_ts_CO
2
1
0
-1
-2
-3
2018
2019
2020
2021
2022
2023
Time

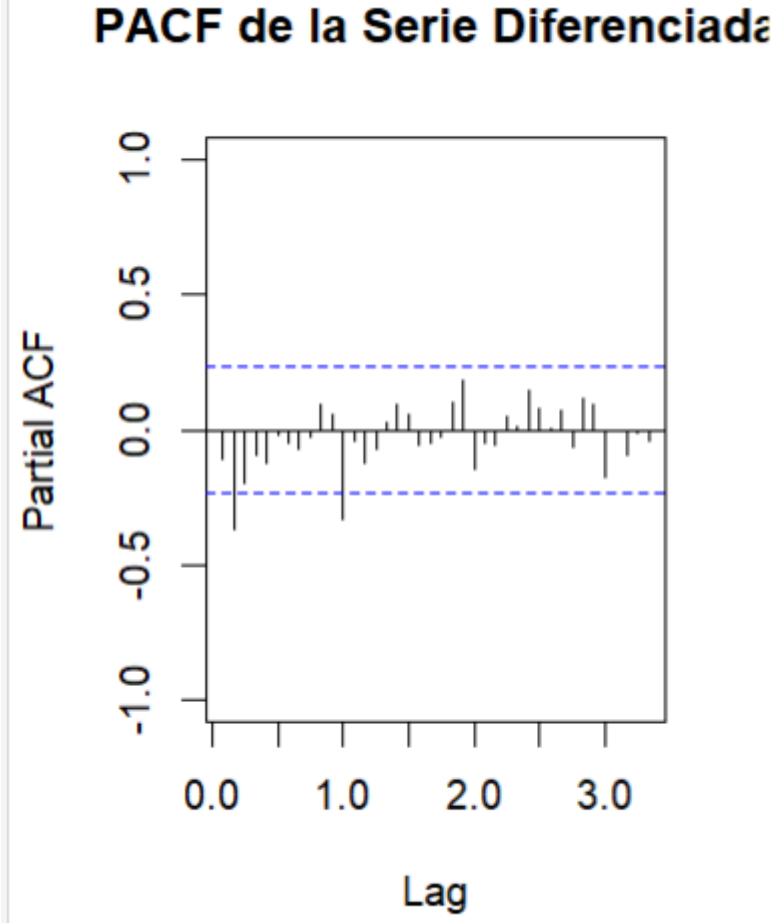
PACF de la Serie Diferenciada
Partial ACF
1.0
0.5
0.0
-0.5
-1.0
0.0
1.0
2.0
3.0
Lag

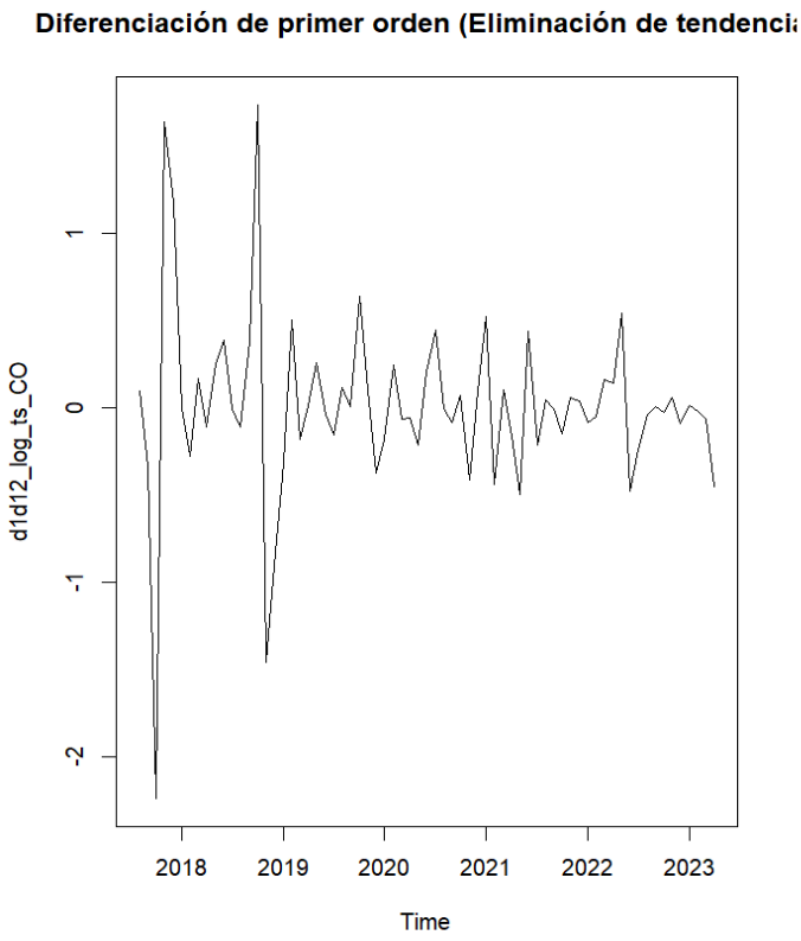

Aquestes transformacions ens permeten obtenir una sèrie que hauria de comportar-se de manera més estacionària. Ara que ja hem transformat la sèrie temporal en un serie estacionaria podem ajustar un model ARMA.

4. Ajustament del model ARMA(1,1)

Amb la sèrie ja diferenciada i estacionària, ajustem un model **ARMA(1,1)**, que inclou:

- **AR(1)**: component autoregressiu d'ordre 1.
- **MA(1)**: component de mitjana mòbil d'ordre 1.

El resum del model mostra que els coeficients de les components AR i MA són significativament diferents de zero, cosa que indica un bon ajust. El criteri AIC és **101.22**, un valor raonable per aquest model.

```
Call:
arima(x = d1d12_log_ts_CO, order = c(1, 0, 1))

Coefficients:
         ar1      ma1  intercept
      0.5013  -0.8970     0.0121
s.e.  0.1625   0.0998     0.0136

sigma^2 estimated as 0.2303:  log likelihood = -47.61,  aic = 101.22

Training set error measures:
```

5. Anàlisi dels Residus del Model

Per verificar la idoneïtat del model, es dibuixen els residus. Idealment, els residus haurien de comportar-se com a soroll blanc, sense mostrar autocorrelacions significatives.

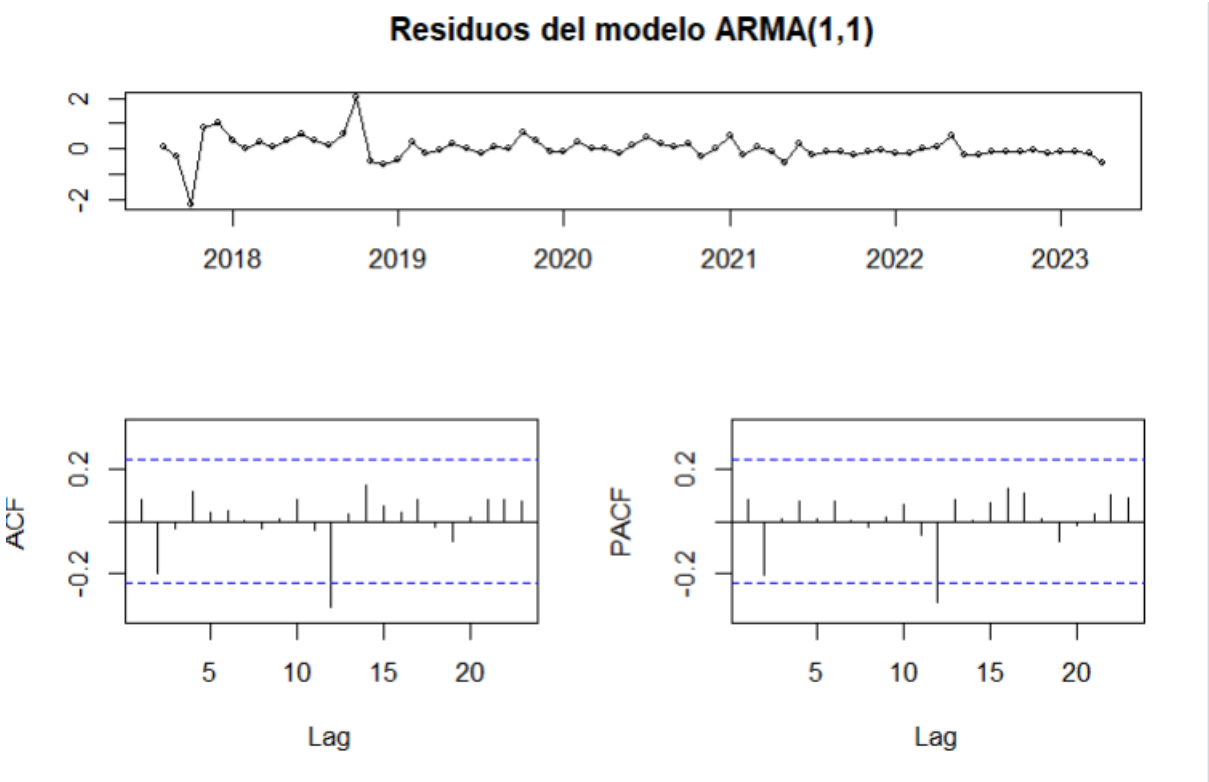

Els gràfics ACF i PACF dels residus no mostren correlacions significatives, la qual cosa suggereix que el model ARMA(1,1) ha capturat correctament l'estructura de la sèrie.

6. Conclusió

El model ARMA(1,1) ajustat a la sèrie temporal diferenciada de CO sembla ser adequat. Les transformacions realitzades han permès que la sèrie esdevingui estacionària, i els residus del model mostren que no hi ha patrons d'autocorrelació significatius. Aquest model pot utilitzar-se per fer prediccions futures o per a un anàlisi més detallat de la dinàmica del CO al llarg del temps.

★ Millores realitzades

1. Transformació Box-Cox

Un dels canvis més importants introduïts va ser la substitució de la transformació logarítmica per una transformació Box-Cox. Aquesta transformació permet estabilitzar la variabilitat i fer que les dades siguin més propenses a complir les assumpcions d'estacionaritat necessàries per ajustar un model ARMA.

En el nostre cas, el valor estimat de λ va ser 1.02, la qual cosa indica que les dades gairebé no requereixen una transformació dràstica, però el petit ajust aporta estabilitat a la variància i millora la qualitat del model.

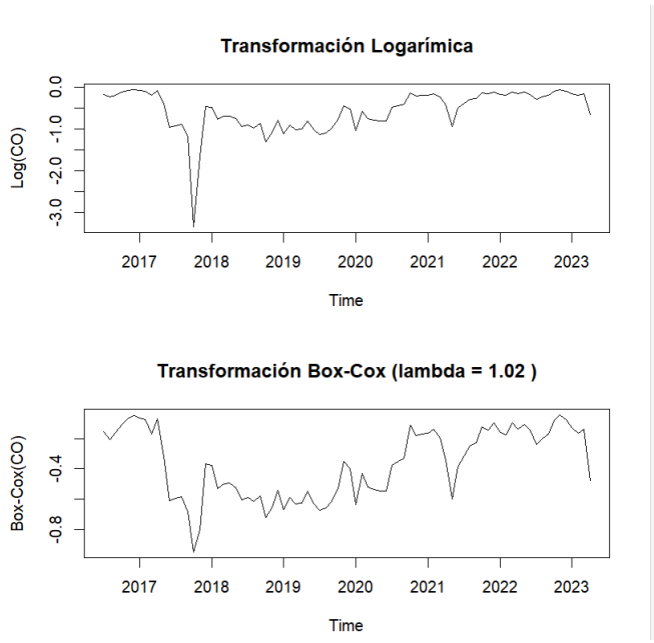

2. Diferenciació de la Sèrie

Per convertir la sèrie en estacionària, es va aplicar diferenciació d'ordre 12, un pas necessari per eliminar l'estacionalitat deguda als cicles anuals. A més, es va afegir una diferenciació addicional d'ordre 1 per eliminar la tendència a llarg termini present en les dades.

Aquest enfocament combinat va permetre obtenir una sèrie transformada i diferenciada que compleix els requisits per ajustar un model ARMA de manera efectiva.

Com es pot observar novament, el model amb box-cox sembla ajustar-se millor amb les dades que estem estudiant.

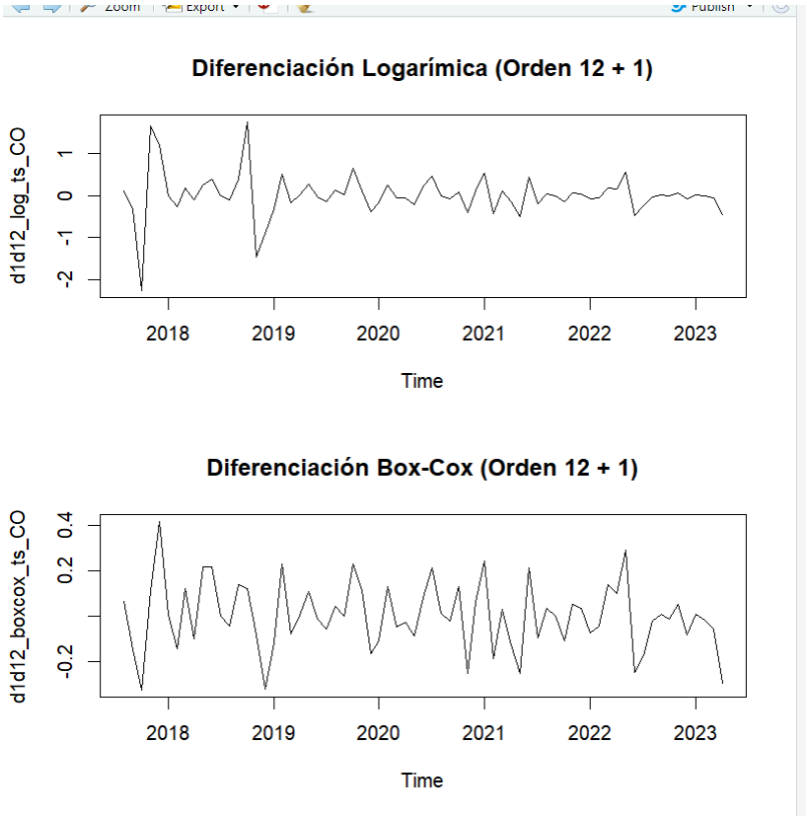

3. Selecció i Ajust de Models ARMA

Es va realitzar una exploració de diferents configuracions de models ARMA variant els paràmetres (p, d, q). El criteri utilitzat per seleccionar el model va ser el valor més baix del AIC, que combina la qualitat de l'ajust amb la simplicitat del model.

Finalment, es va identificar el model ARMA(1,0,2) com el millor ajust per a la sèrie. Aquest model presenta un valor AIC de – 68.31, significantment més baix que el

model anterior. L'inclusió del segon terme MA (q=2) va permetre capturar millor la dinàmica dels errors presents a la sèrie.

4. Avaluació del Model ARMA(1,0,2)

Per verificar la qualitat del model, es van analitzar els residus generats. Els residus haurien de comportar-se com a soroll blanc, és a dir, haurien de ser independents i no presentar cap patró detectable.

Els resultats van mostrar que:

- Els residus estaven distribuïts al voltant de zero, sense evidència de patrons significatius en els gràfics ACF i PACF.
- La prova de Ljung-Box va confirmar l'absència d'autocorrelació significativa en els residus amb un p-valor = 0.3304, superant el llindar habitual de 0.05.

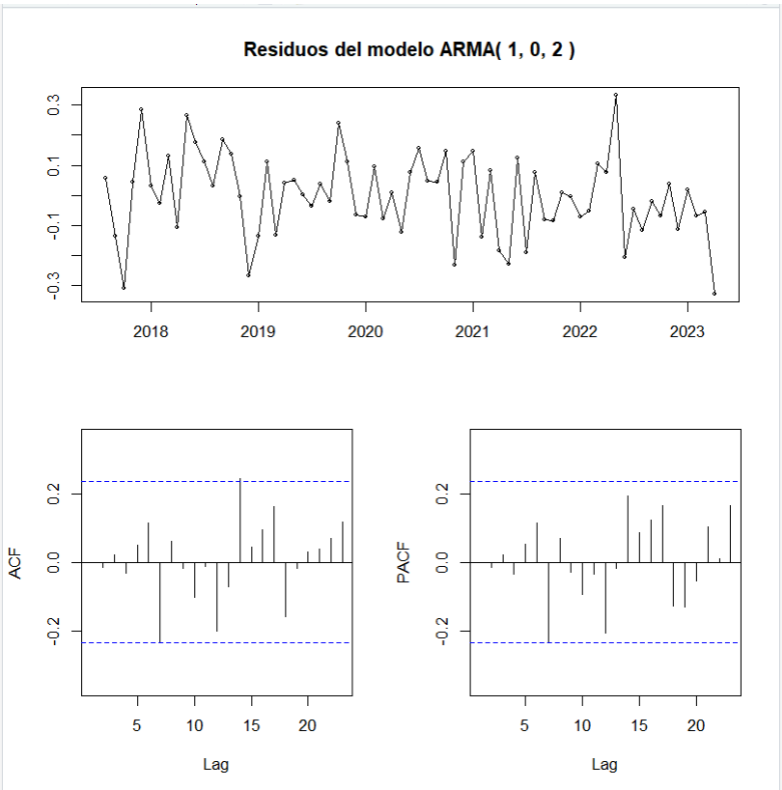

5. **Predicció amb el time series(forecast):**

En aquest gràfic es mostra la predicció del millor model ARMA(1,0,2) aplicat a la sèrie temporal de concentració de CO mensual. La predicció s'ha realitzat després d'aplicar la transformació Box-Cox amb λ=1.02 i la seva corresponent transformació inversa per tornar a la escala original.

<u>Interpretació del Gràfic</u>

- La línia negra representa els valors històrics de la concentració de CO (mg/m³) des del 2016 fins al 2023.
- La predicció per als pròxims 12 mesos s'observa com una extensió de la sèrie original a partir de finals del 2023.
- Les línies blaves discontínues corresponen als intervals de confiança del 95%, que indiquen la incertesa associada a la predicció. Aquests intervals s'eixamplen a mesura que ens allunyem en el temps, cosa que és normal en qualsevol predicció.
- Tal com es pot observar en el gràfic, els valors previstos per a l'any 2024 se situen al voltant de **0.8 mg/m3**. Aquests resultats es mostren amb la línia de predicció central i amb els intervals de confiança al 95%, que reflecteixen la incertesa creixent a mesura que avancem en el temps.

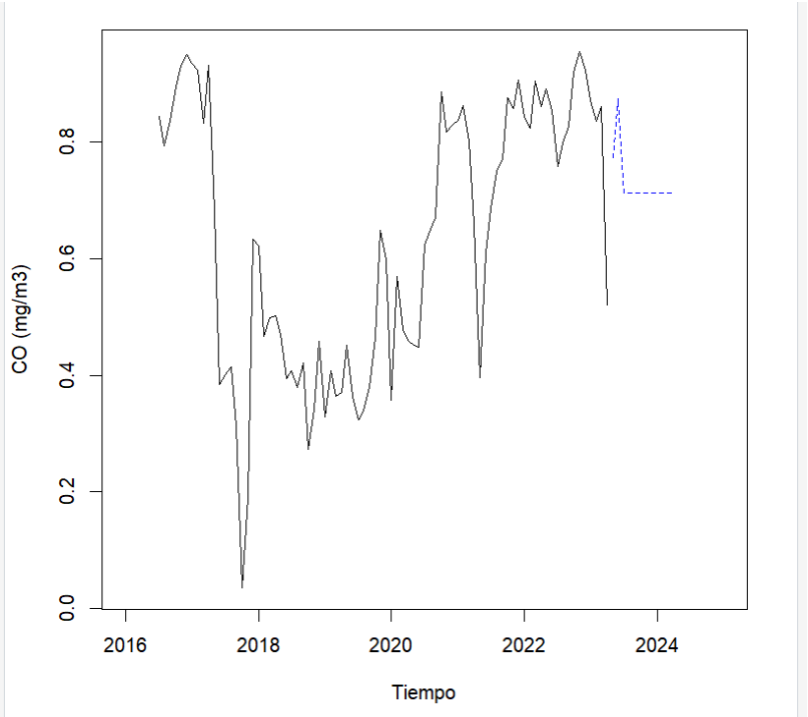

5. Principal Components Analysi (PCA)

En aquest projecte de modelització estadística, hem aplicat l'Anàlisi de Components Principals (PCA) com a tècnica de reducció de dimensionalitat per identificar les variables més importants i eliminar redundàncies en el conjunt de dades. L'objectiu principal d'aquesta anàlisi és simplificar el model mantenint el màxim nivell d'informació possible, la qual cosa millora la interpretabilitat i eficiència del model sense sacrificar precisió.

Per determinar el nombre de components principals a retenir, hem analitzat la variància explicada per cadascun d'ells. A la primera gràfica, es mostra un gràfic de barres amb la variància explicada per cada component. Com es pot observar, els primers components acumulen una proporció significativa de la variància, mentre que els components restants aporten molt poca informació addicional.

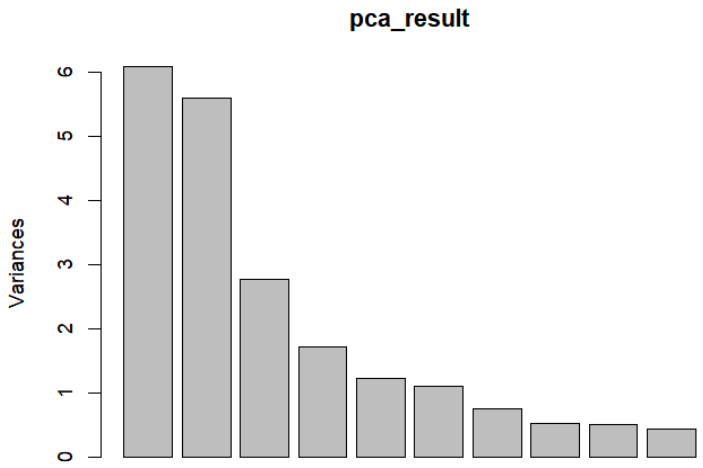

A la segona gràfica, es presenta un gràfic de línies(scree plot) que il·lustra la variància explicada acumulada per cada component. Aquest gràfic ens permet visualitzar el punt en què la variància addicional explicada per cada nou component és marginal, la qual cosa indica el nombre òptim de components per mantenir en el model.

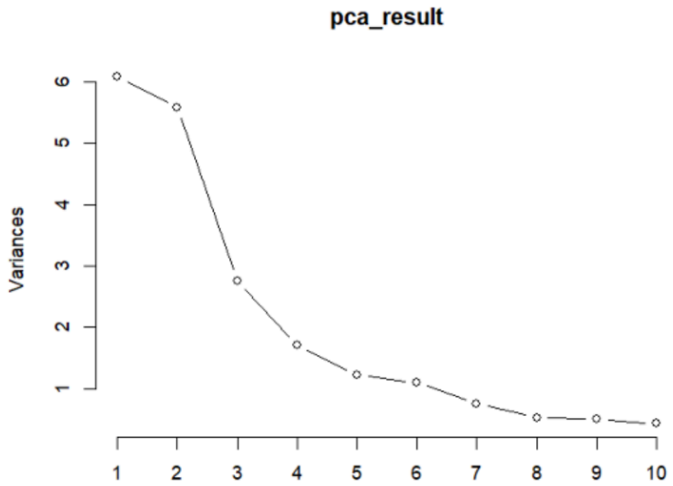

```
Importance of components:
                          PC1    PC2    PC3     PC4    PC5     PC6     PC7     PC8     PC9    PC10   PC11    PC12    PC13    PC14
Standard deviation     2.4668 2.3636 1.6622 1.30945 1.1060 1.05022 0.87198 0.72528 0.71386 0.65775 0.6276 0.54998 0.47345 0.43691
Proportion of Variance 0.2766 0.2540 0.1256 0.07794 0.0556 0.05013 0.03456 0.02391 0.02316 0.01967 0.0179 0.01375 0.01019 0.00868
Cumulative Proportion  0.2766 0.5305 0.6561 0.73407 0.7897 0.83980 0.87437 0.89828 0.92144 0.94111 0.9590 0.97276 0.98295 0.99162
                          PC15    PC16    PC17   PC18    PC19    PC20    PC21    PC22
Standard deviation     0.3110 0.17276 0.12194 0.1052 0.09679 0.09242 0.08587 0.08024
Proportion of Variance 0.0044 0.00136 0.00068 0.0005 0.00043 0.00039 0.00034 0.00029
Cumulative Proportion  0.9960 0.99738 0.99805 0.9986 0.99898 0.99937 0.99971 1.00000
```

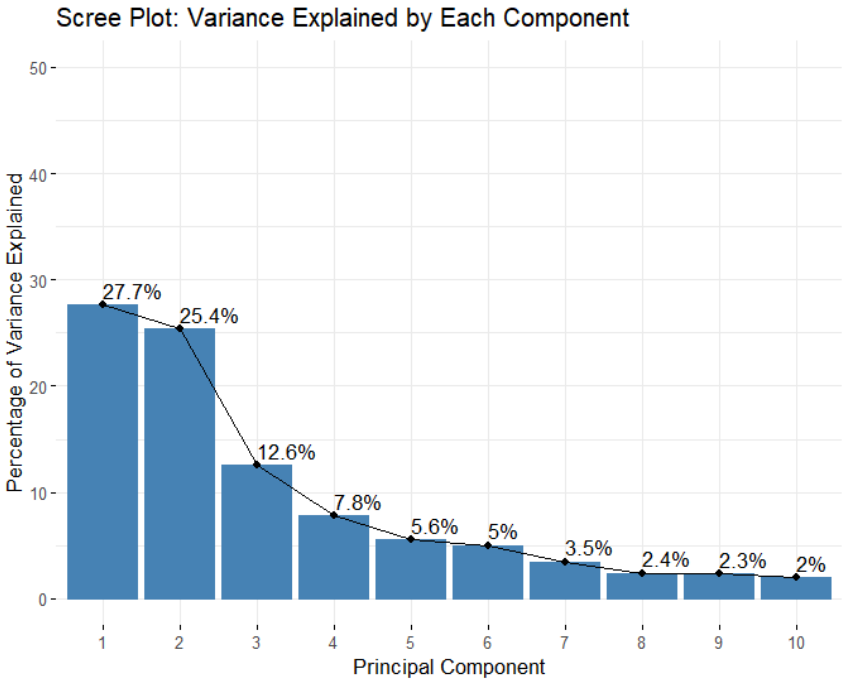

Després d'analitzar aquests gràfics i la taula, hem decidit quedar-nos amb els primers **5 components** que expliquen més del **78,97%** de la variància total. Aquesta decisió ens permet conservar la informació més rellevant de les dades, i l'hem prés perquè amb el scree plot si seguim la regla del colze podem observar que ens podem quedar amb unes 5 components o fins i tot només 4, però si volem que el nostre model segueixi explicant entre un 80-90% de les dades totals hauríem d'utilitzar com a mínim 6, per tant fent una mitjana d'aquests dos números hem decidit que utilitzar 5 components és el més ideal per fer PCA.

<u>Anàlisi del Biplot de PCA</u>

En el biplot presentat a la figura 4, representem tant les observacions (mostres individuals) com les variables originals en el pla definit pels dos primers components principals (Dim1 i Dim2), que expliquen un percentatge significatiu de la variància

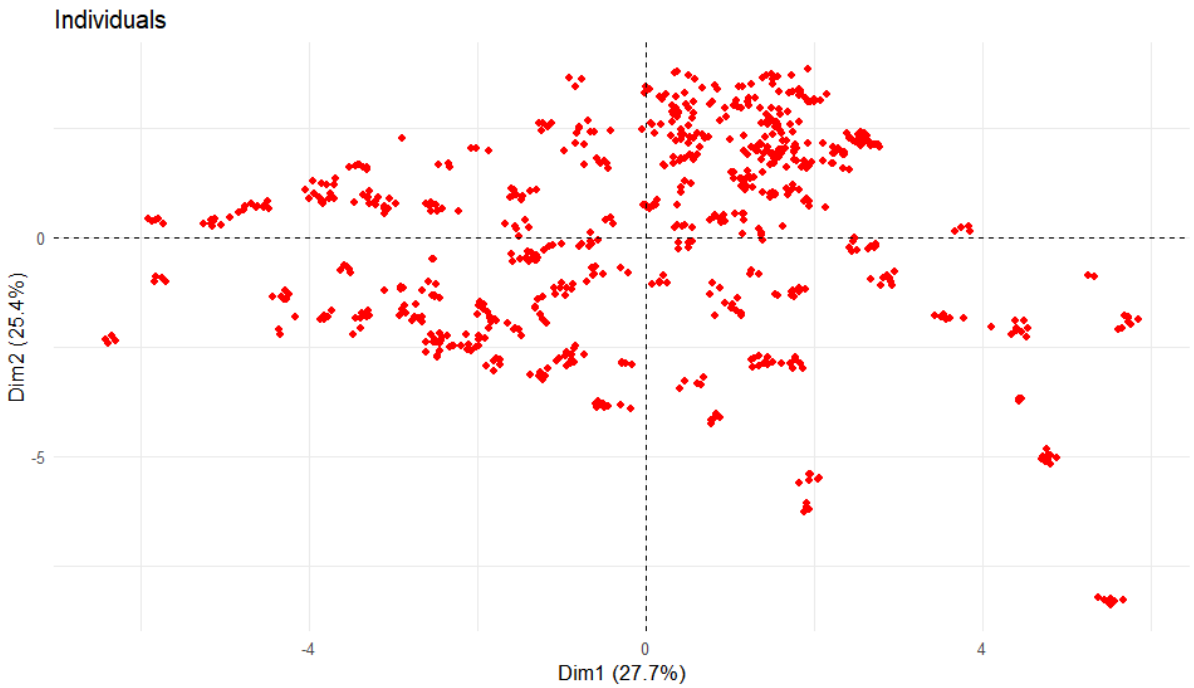

(aproximadament el 27,7% i el 25,4% respectivament).

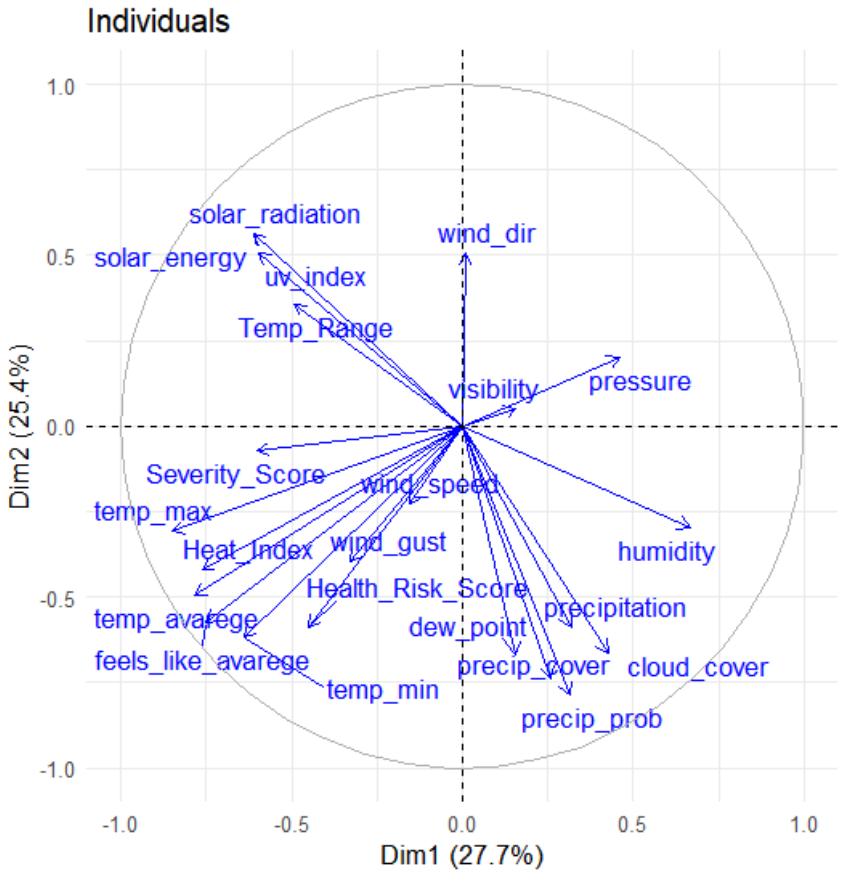

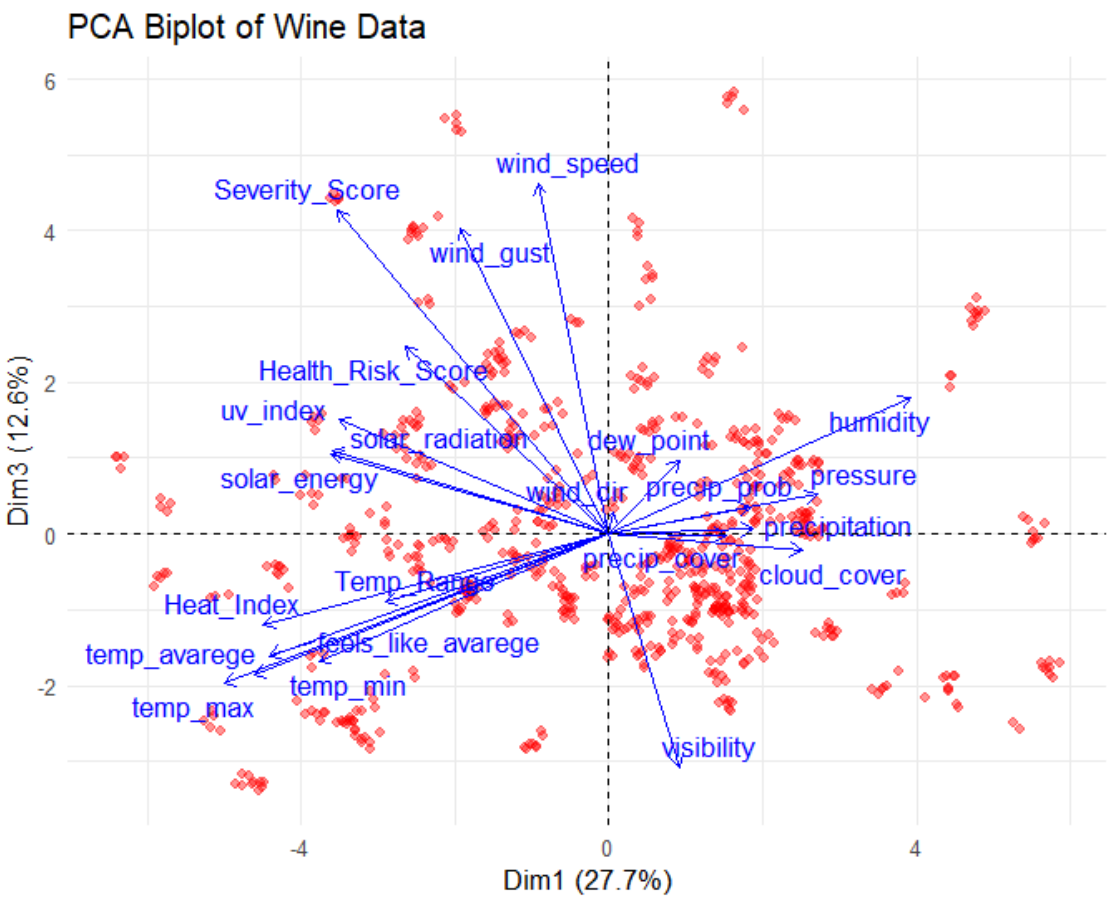

Les variables més representades en aquest biplot són aquelles amb vectors més llargs, ja que aquests indiquen una contribució elevada en els components principals. Entre aquestes variables trobem **"solar_radiation"**, **"wind_speed"** i **"uv_index"** en una direcció i **"visibility"**, **"pressure"** i **"humidity"** en una altra. Aquestes variables tenen una major influència en el primer o segon component, i per tant, contribueixen en major mesura a explicar la variància en les dades.

Un aspecte rellevant en el biplot és que la proximitat i l'angle entre els vectors de les variables ens permet inferir relacions de correlació entre aquestes:

- **Variables amb correlació positiva**: Les variables que formen un angle petit entre si (per exemple, **"solar_radiation"** i **"uv_index"**) estan correlacionades positivament, la qual cosa indica que augmenten conjuntament en les observacions. Això és esperable ja que tant la radiació solar com l'índex UV tendeixen a incrementar-se simultàniament en condicions de sol intens.
- **Variables amb correlació negativa**: Les variables que es troben en direccions oposades (angles de 180 graus), com ara **"humidity"** i **"temp_max"**, estan negativament correlacionades. Això suggereix que quan la humitat és alta, la temperatura màxima tendeix a ser menor, i viceversa.
- **Variables ortogonals (sense correlació)**: Les variables que formen un angle recte no estan correlacionades entre si. En aquest cas, **"wind_dir"** i

"temp_range" són gairebé ortogonals, la qual cosa indica que les variacions en la direcció del vent no estan relacionades amb la variabilitat de la temperatura en aquest conjunt de dades.

La interpretació dels components és la següent:

- **Dim1 (27.7%)**: Aquest component sembla estar fortament influenciat per variables relacionades amb les condicions climàtiques (com **"solar_radiation"**, **"uv_index"** i **"temp_range"**). Aquest component podria representar una dimensió de "intensitat solar i variabilitat de temperatura", ja que agrupa factors que s'incrementen conjuntament en dies amb més sol i temperatures fluctuants.
- **Dim2 (25.4%)**: Aquest component està dominat per variables com **"pressure"**, **"visibility"** i **"humidity"**, suggerint una dimensió més relacionada amb la humitat i la pressió atmosfèrica. Aquesta dimensió podria representar l'estat atmosfèric en termes de "estabilitat atmosfèrica", agrupant variables associades a la humitat i la visibilitat, així com la pressió.

La figura 5 mostra la contribució de les variables a cada component. Això ens ajuda a identificar quines variables tenen un impacte més significatiu en la variància explicada per cada component. Les variables amb contribucions més altes en Dim1, com **"solar_radiation"** i **"uv_index"**, són les més importants per a la dimensió d'intensitat solar, mentre que per a Dim2, **"humidity"** i **"pressure"** són determinants de la dimensió d'estabilitat atmosfèrica.

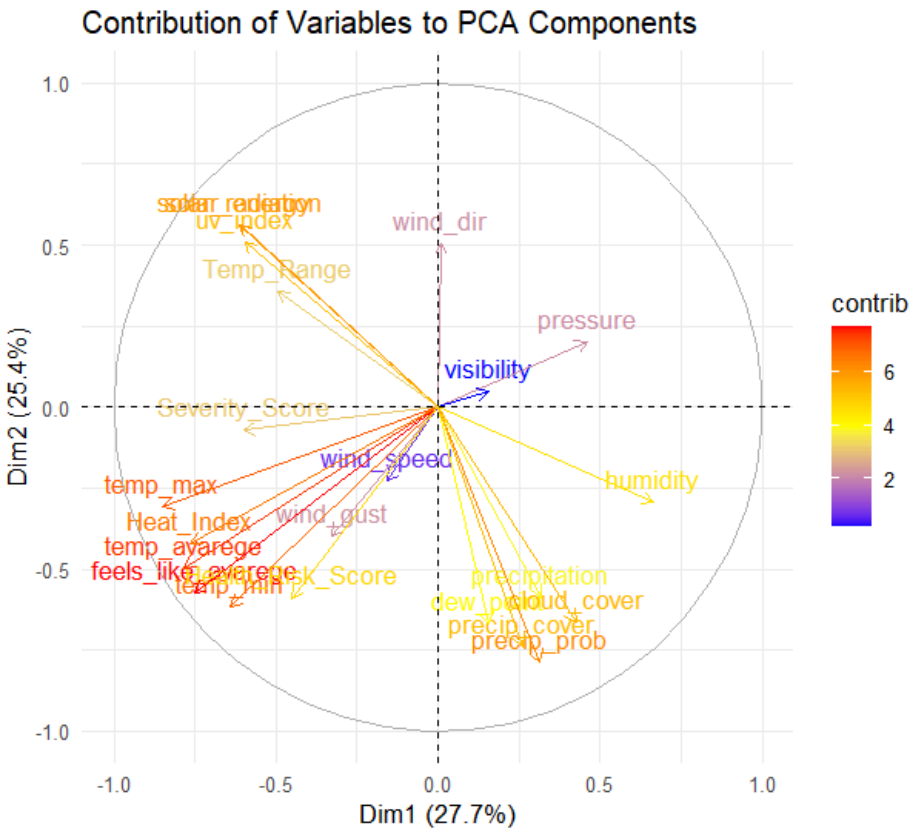

El gràfic inferior mostra el **PCA d'individus (mostres)**, amb una codificació de colors segons la ciutat de cada mostra. Aquest gràfic ens permet explorar si es formen clústers de mostres en funció de la ciutat d'origen, la qual cosa indicaria que certes ciutats comparteixen condicions similars de les variables analitzades.

- **Formació de Clústers**: S'observa que algunes ciutats mostren tendències a agrupar-se en el gràfic. Per exemple, mostres de **ciutats com Phoenix i Houston** (en colors distintius) tendeixen a estar concentrades en una mateixa regió del gràfic, la qual cosa suggereix que podrien compartir característiques similars en termes de les variables climàtiques o ambientals.
- **Ciutats amb dispersió alta**: Altres ciutats, com **New York City** i Chicago, tenen mostres més disperses, cosa que pot indicar una major variabilitat en les condicions de les variables representades. Aquesta dispersió podria estar relacionada amb la variabilitat geogràfica i climàtica d'aquestes ciutats.

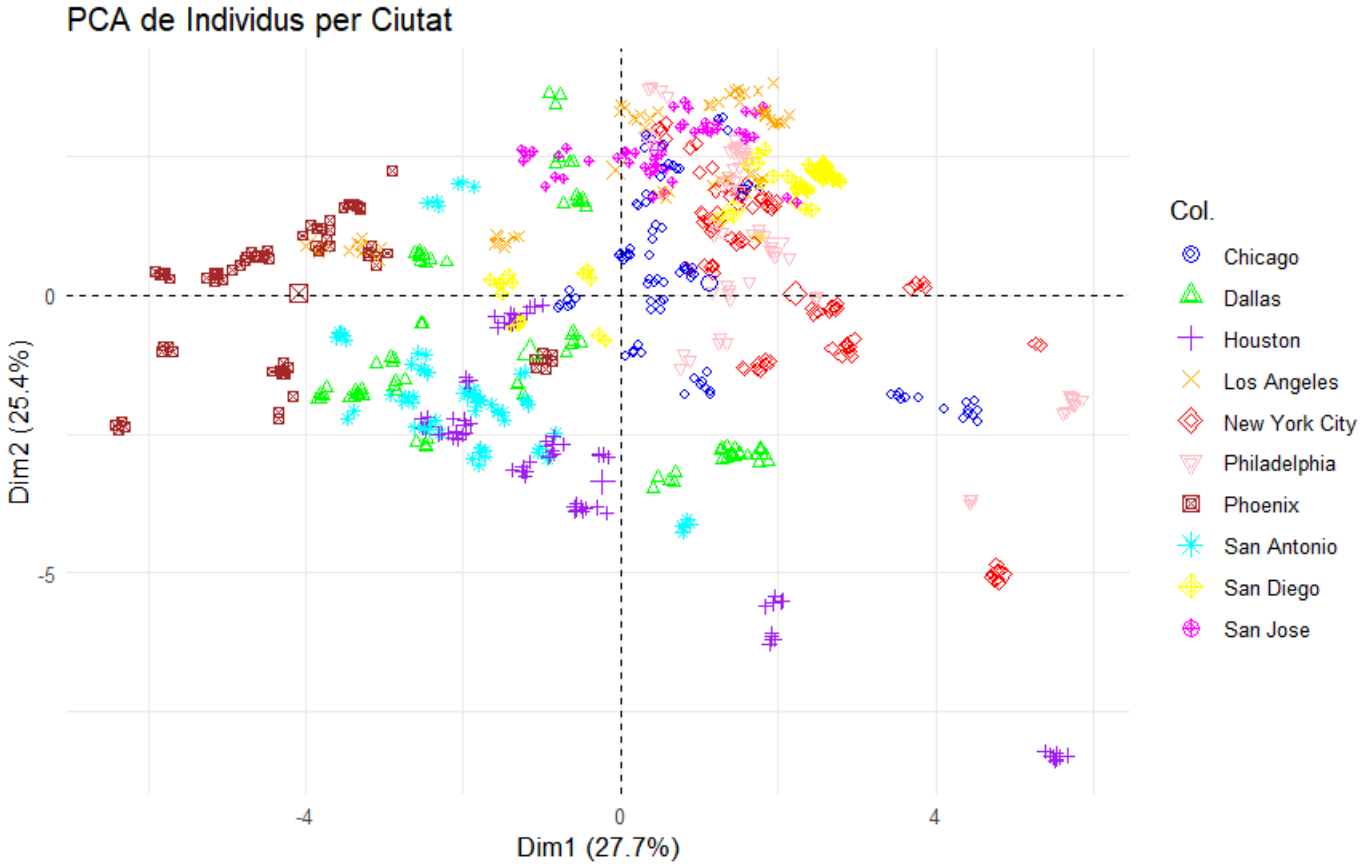

En conclusió, mitjançant l'aplicació de PCA, hem reduït el nombre de variables en el nostre model, mantenint alhora la informació més rellevant. Hem seleccionat 5 components que expliquen més del **78,97%** de la variància total. Les dues primeres dimensions capturen la major part de la variància i ens proporcionen una bona representació de les relacions entre les variables.

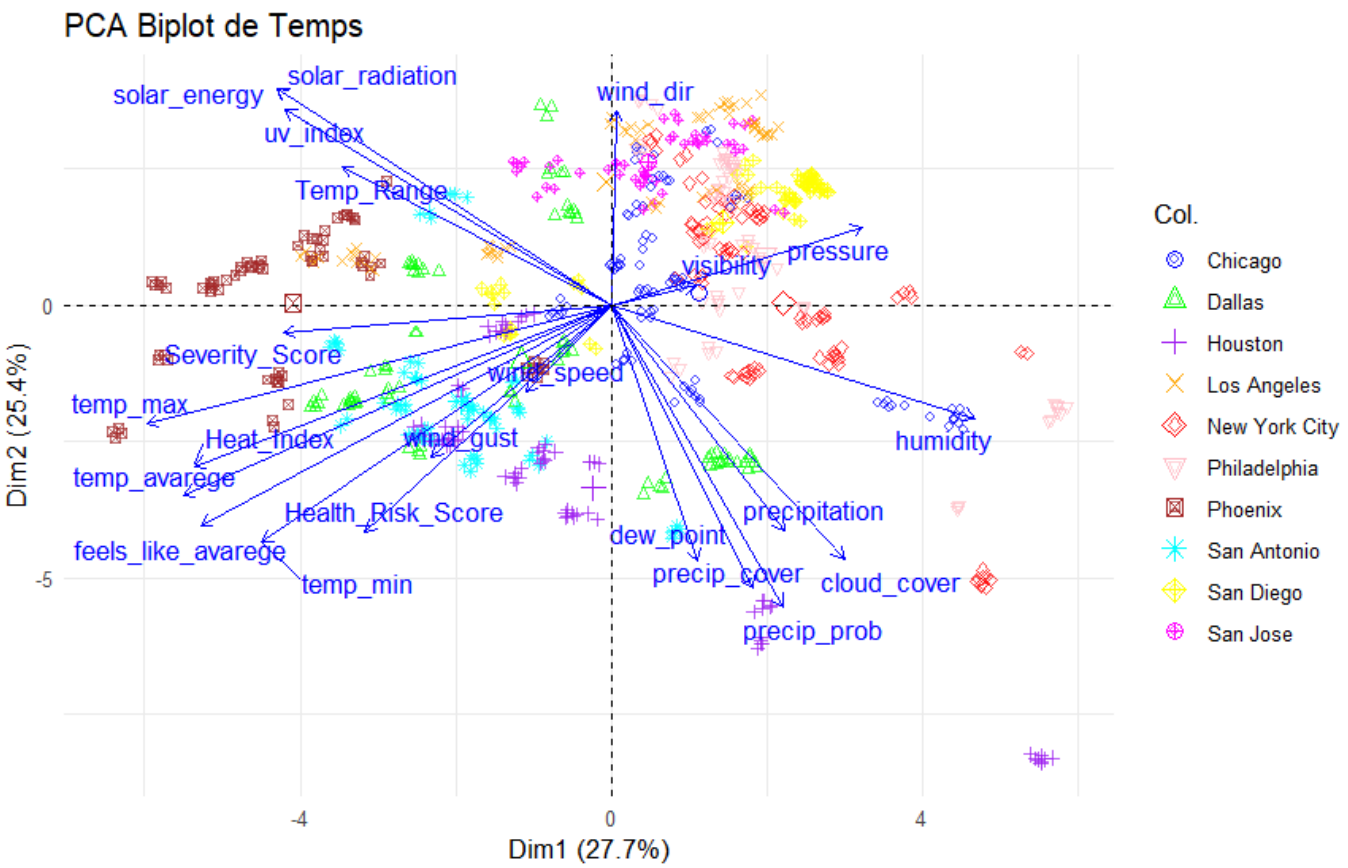
PCA Biplot de Temps
solar_energy
solar_radiation
uv_index
Temp_Range
wind_dir
visibility
pressure
Severity_Score
wind_speed
temp_max
Heat_Index
wind_gust
humidity
temp_avarege
Health_Risk_Score
precipitation
dew_point
feels_like_avarege
temp_min
precip_cover
cloud_cover
precip_prob
Dim2 (25.4%)
Dim1 (27.7%)
0
-5
-4
0
4
Col.
Chicago
Dallas
Houston
Los Angeles
New York City
Philadelphia
Phoenix
San Antonio
San Diego
San Jose

6. Clustering

6.1 Hierarchical Clustering

En el nostre projecte hem utilitzat la metodologia de clusterització jeràrquica per avalua les possibles agrupacions de les nostres observacions.

En primer lloc hem seleccionat únicament les columnes numèriques per a normalitzar-les mitjançant la funció scale, garantint així la comparabilitat entre variables.

A continuació, hem avaluat la tendència a agrupar-se de les dades calculant l'índex d'Hopkins, que mesura l'estructura de clustering intrínseca en el conjunt de dades. Obtenim el valor 1, per tant indica que hi ha una estructura de clustering perfectament definida. Això vol dir que les dades tenen una molt forta tendència a agrupar-se i estan organitzats de forma intrínseca en cluster clars i separats.de manera intrínseca en clusters claros y separados.

Després hem generat les visualitzacions exploratòries següents per a comprendre millor la distribució de les variables:

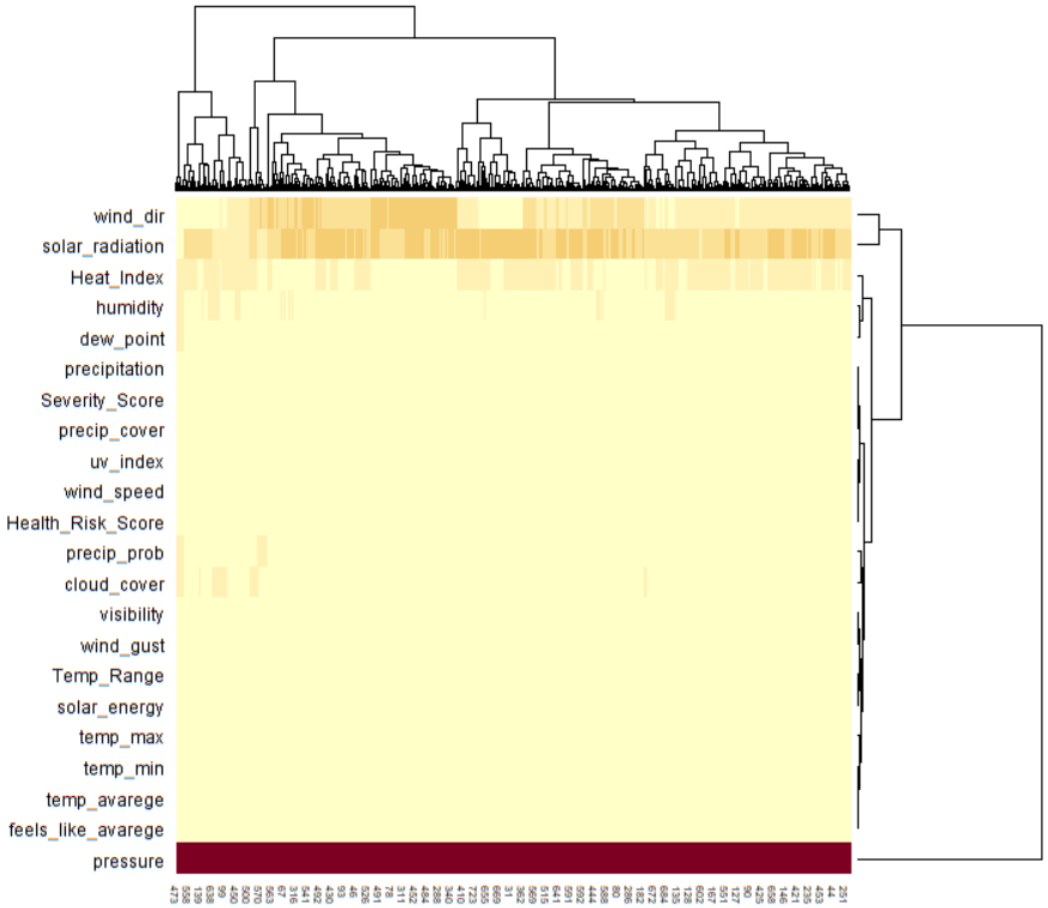

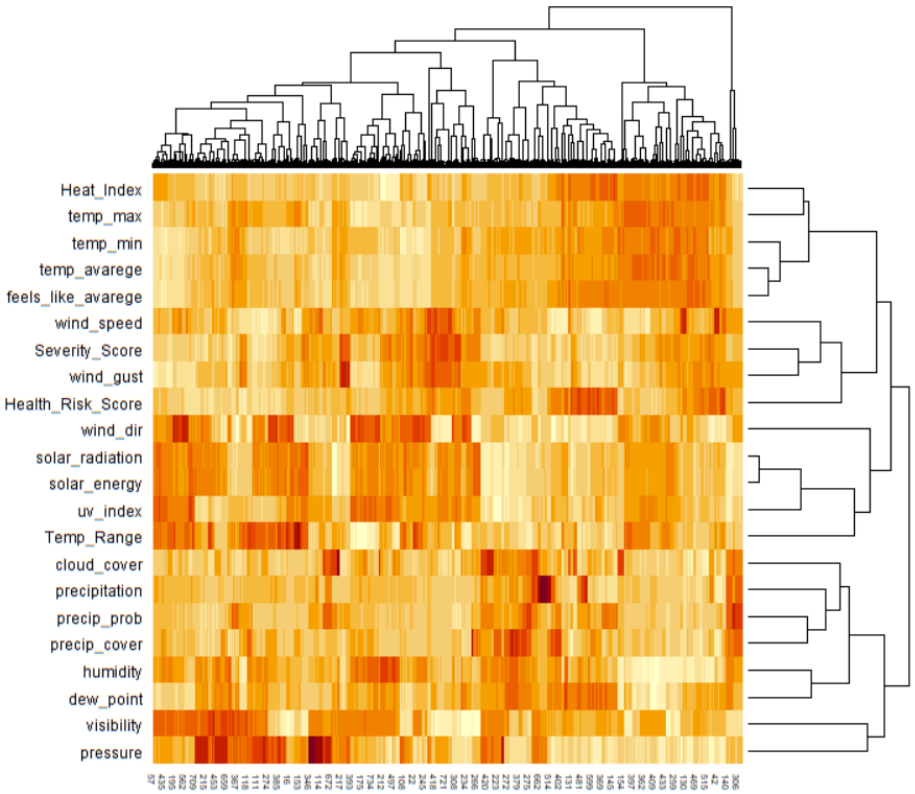

Després calculem la matriu de distàncies euclidianes entre observacions com a base per al clustering jeràrquic. Aquesta matriu es visualitza tant numèricament com mitjançant gràfics per a obtenir una idea inicial de les relacions entre les observacions.

Un cop tenim la matriu de distàncies contruïm els osteriorment, es construeixen dendogramas amb els mètodes d'enllaç complet i Ward.D2, i s'avaluem la qualitat dels agrupaments mitjançant la correlació cophenética.
El millor valor de correlació cophenética l'obtenim amb la distància complete (0'706).

Ara ens falta determinar el nombre de clusters que hem d'agafar. Primer fem el gràfic:

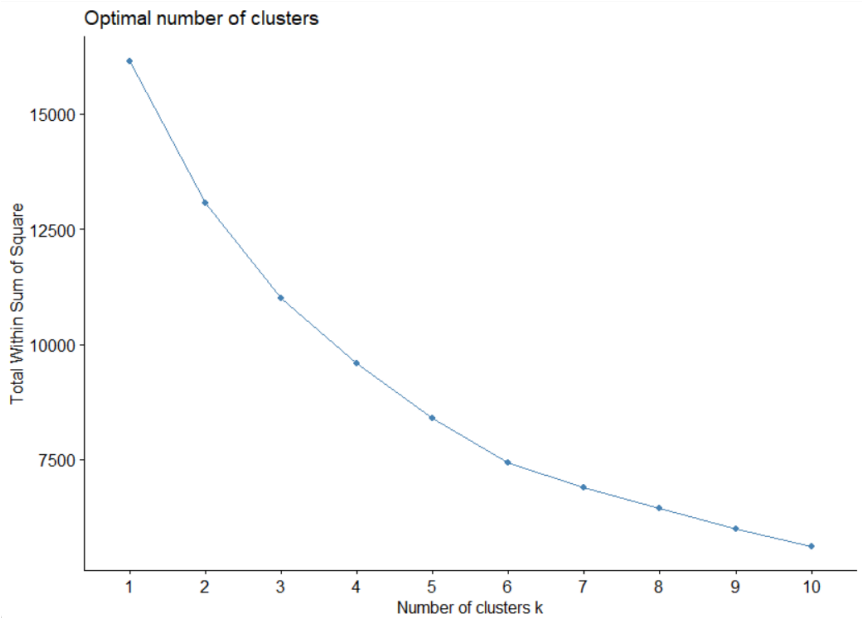

Determinar el nombre òptim de clústers aplicant la “Elbow Rule” no resulta una opció fiable, per tant utilitzem el paquet NbClust, que considera múltiples criteris estadístics. El resultat que optenim és que el millor valor pel nombre de clusters és 3.

Finalment, seleccionem tres clústers, i aquesta informació s'agrega com una nova columna en les dades normalitzades. Els resultats els visualitzem amb un dendograma acolorit.

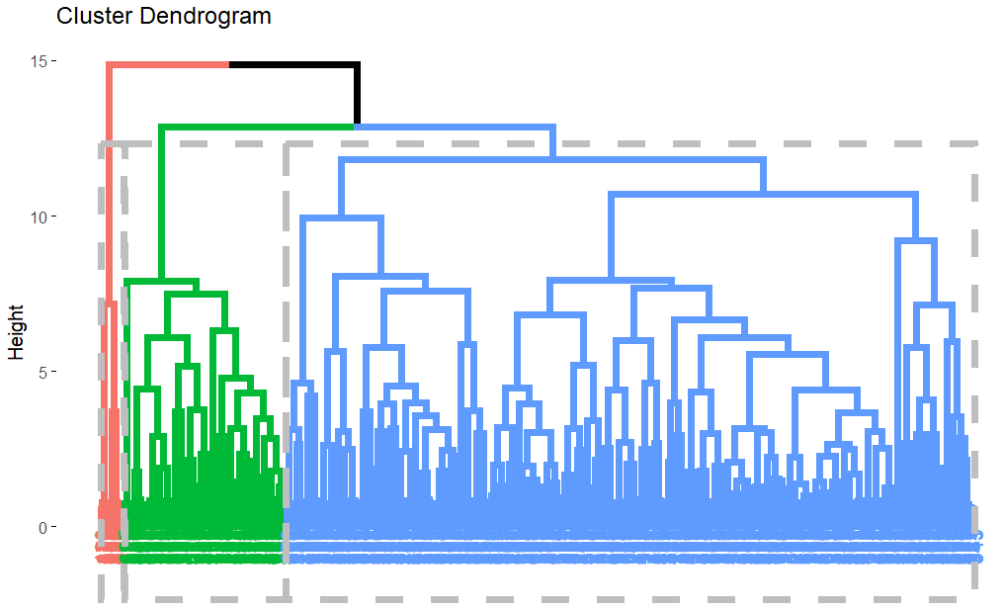

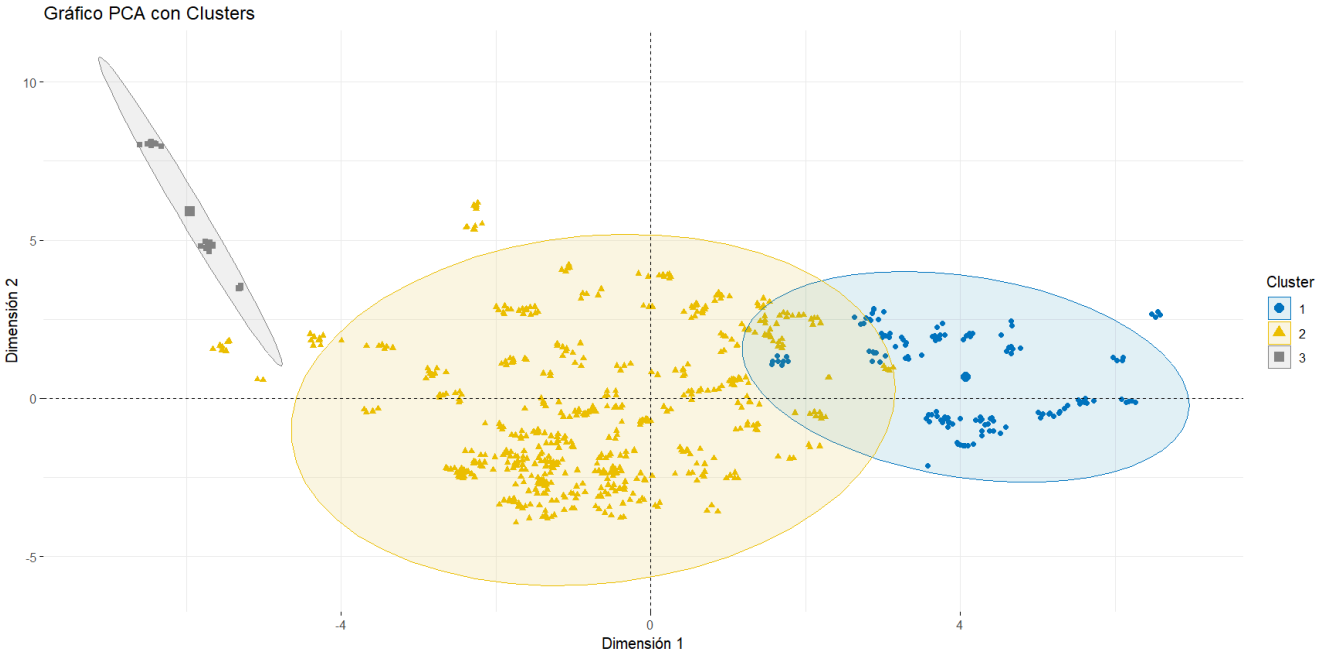

A més, hem volgut intentar analitzar també les relacions entre els clústers i les ciutats representades en les dades. Per a això, hem construït taules creuades i gràfics de barres apilades que mostren la distribució dels clústers per ciutat.

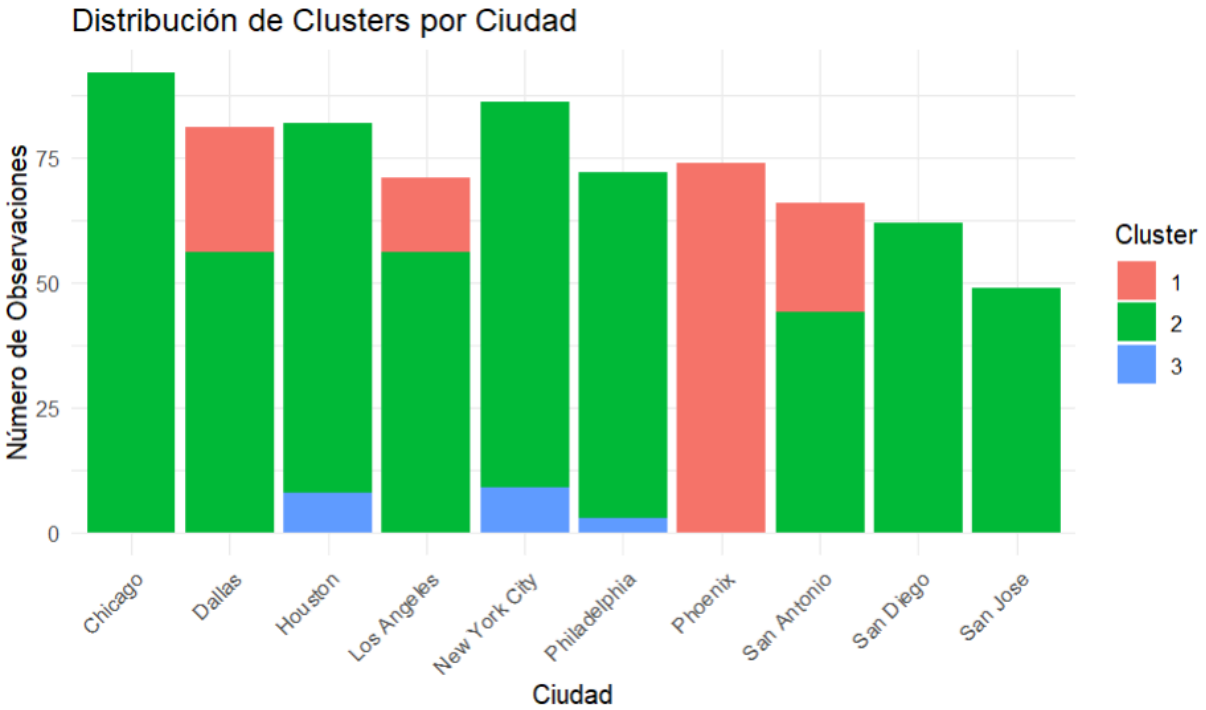

No podem obtenir cap conclusió encara, esperem que al fer el profiling puguem entendre l'assignació dels clusters en relació amb les variables de la base de dades.

6.2 Partitional Clustering

Per a iniciar l'anàlisi, com ja hem calculat anteriorment lìndex de Hopkins, hem utilitzat la funció NbClust per determinar el nombre òptim de clusters per a una

clusterització particional. Aquesta funció avalua múltiples índexs per suggerir el nombre més adequat de clusters. Tal com es mostra en el barplot, la majoria dels índexs suggereixen que el nombre òptim de clusters és 5. Per tant, hem treballat amb aquest nombre en les següents metodologies de clusterització.

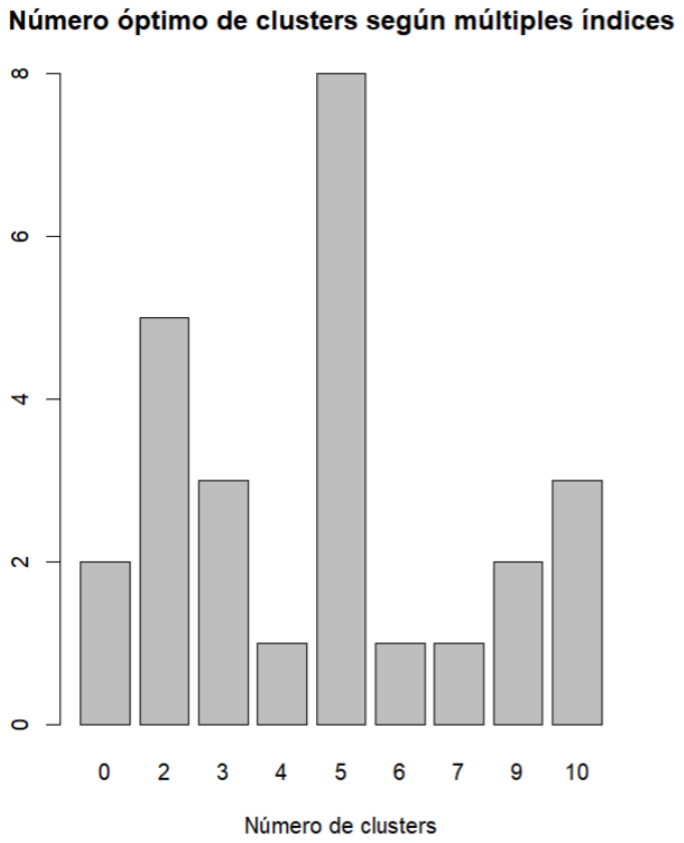

Prova de diferents metodologies de clusterització:

Hem provat tres maneres diferents de realitzar la clusterització:

1. **K-means amb distància de Gower:** Aquesta metodologia s'utilitza per combinar dades mixtes (numèriques i categòriques). Permet integrar variables heterogènies, com la temperatura i la regió.
2. **K-means amb dades numèriques escalades:** Aquest enfocament utilitza únicament les variables numèriques després d'escalar-les, aplicant la distància euclidiana.
3. **K-medoids amb PAM (distància de Gower):** Una metodologia més robusta que permet treballar amb dades mixtes utilitzant la distància de Gower per calcular similituds.

Comparació entre metodologies amb Rand Index:

Els resultats de Rand Index són els següents:

- **Rand Index entre K-means i K-medoids:** 0.7505, indicant una similitud moderada.
- **Rand Index entre K-prototype i K-medoids:** 0.6970, suggerint una similitud també moderada.
- **Rand Index entre K-prototype i K-means:** 0.6871, una mica inferior als altres dos.

Tot i que la diferència en el Rand Index entre les metodologies és petita, **K-means (només numèric)** ha estat preferit per la seva simplicitat i facilitat d'interpretació, especialment quan les variables categòriques no són dominants. A part d'això, no hem trobat cap funció que permet la visualització dels clusters amb el k-prototype.

<u>Visualització dels clusters</u>

Els resultats dels clusters es poden observar en les següents figures:

1. **Clusters amb K-means (dades numèriques escalades):**
    - Els clusters estan ben separats en l'espai de les dues primeres components principals.
    - Cada color representa un cluster, amb formes ben delimitades gràcies a l'escalat de dades.

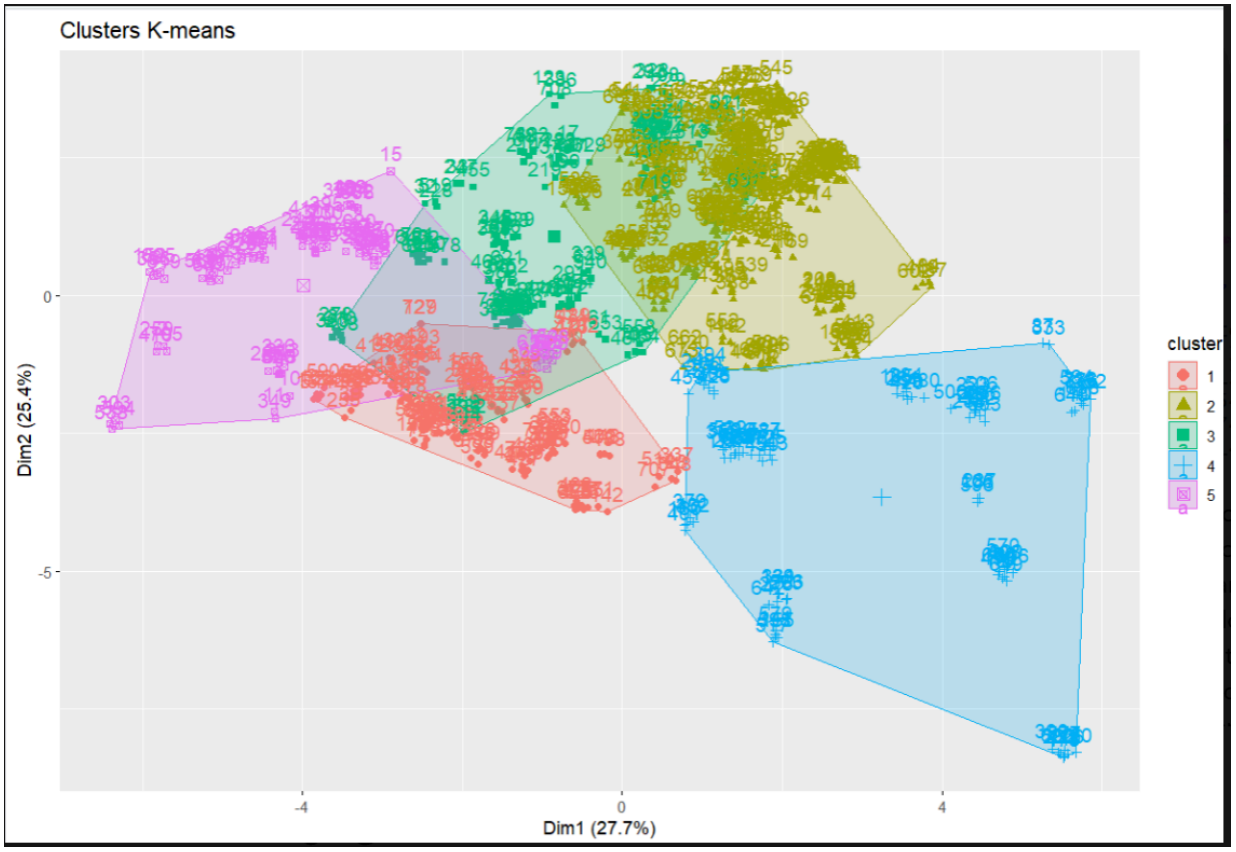

2. **Clusters amb K-medoids (PAM):**

- Aquesta representació també mostra una bona separació dels clusters, però en aquest cas incorpora dades mixtes.
- Les àrees són més irregulars, reflectint la complexitat de combinar dades numèriques i categòriques.

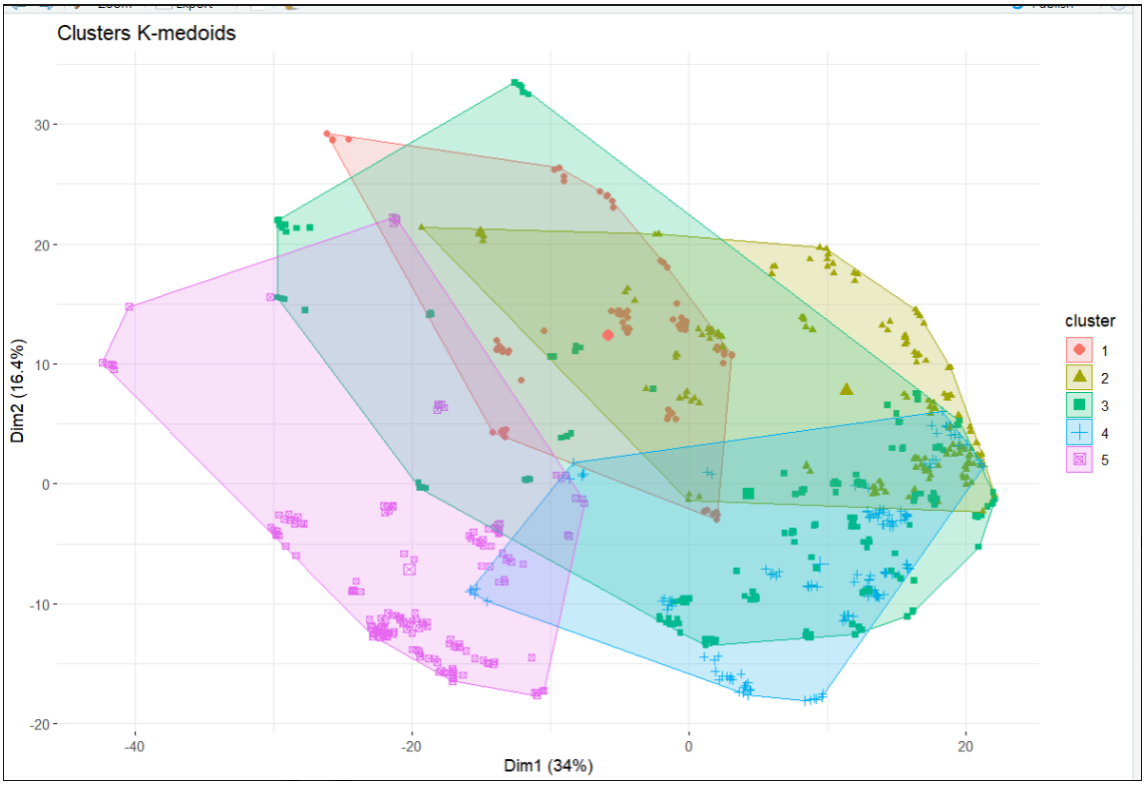

<u>Interpretació geogràfica dels clusters:</u>

Hem analitzat com els clusters es relacionen amb les regions geogràfiques (Nord, Sud, Oest). Les dues taules següents resumeixen la distribució:

- **Taula 1 (quantitats absolutes):**
  - El Cluster 1 està dominat per observacions del Sud (192).
  - El Cluster 2 representa majoritàriament el Nord (120).
  - Els Clusters 3 i 4 estan associats principalment a l'Oest.
  - El Cluster 5 té una distribució més equilibrada entre Nord (122) i Oest (114).

Cluster	Region Norte	Oeste	Sur
1	0	2	192
2	120	12	1
3	8	54	0
4	0	74	16
5	122	114	20

- **Taula 2 (proporcions):**

- El Cluster 1 té un 84% de les observacions al Sud, indicant una forta associació amb aquesta regió.
- El Cluster 2 té un 48% al Nord, mentre que el Cluster 5 es divideix entre el Nord (49%) i l'Oest (45%).
- Els Clusters 3 i 4 tenen una presència clara a l'Oest (21% i 29%, respectivament).

	Region		
Cluster	Norte	Oeste	Sur
1	0.00	0.01	0.84
2	0.48	0.05	0.00
3	0.03	0.21	0.00
4	0.00	0.29	0.07
5	0.49	0.45	0.09

<u>Conclusions:</u>

1. El nombre òptim de clusters és 5, tal com indiquen els índexs de NbClust.
2. Entre les metodologies provades, K-means amb dades numèriques escalades ha estat preferit per la seva simplicitat i interpretabilitat, amb resultats similars als de K-medoids.
3. Geogràficament, els clústers mostren una associació amb les regions, destacant el Sud en el Cluster 1 i l'Oest en els Clusters 3 i 4.

Aquestes observacions suggereixen que la qualitat de l'aire pot tenir relació amb factors geogràfics i regionals, però es podrien explorar més variables per refinar els resultats.

7. Profiling of Clusters

7.1 Hierarchical Clustering

A l'hora de fer el *profiling* dels clústers tenim l'objectiu principal de identificar diferències significatives entre els clústers formats i aprofundir en les característiques de cada grup.

Per començar hem escollit algunes variables que hem considerat significatives basant-nos en els resultats que vam obtenir a l'anàlisi de components principals (PCA) per poder fer-nos una idea general del context en el que ens trobavem abans de començar amb els *tests*. Entre les variables analitzades s'inclouen: l'energia solar, la temperatura mitjana, la probabilitat de precipitació, la direcció del vent i la pressió atmosfèrica.

Entre les variables que major diferències vam trobar es troben:

- La variable *solar_energy* la qual difereix significativament entre els clústers, especialmente entre el 1 i 2 respecte al tercer.

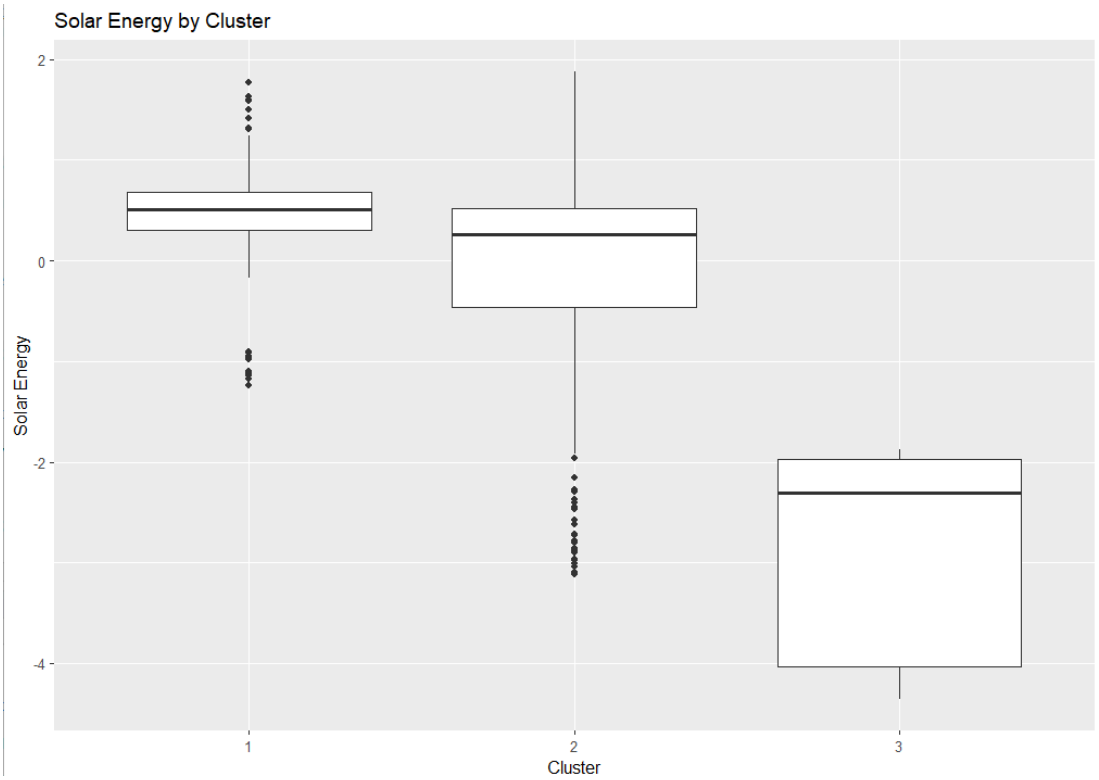

- La variable *temp_average* (la temperatura mitjana) marca una forta diferència entre el clúster 1 i els altres dos.

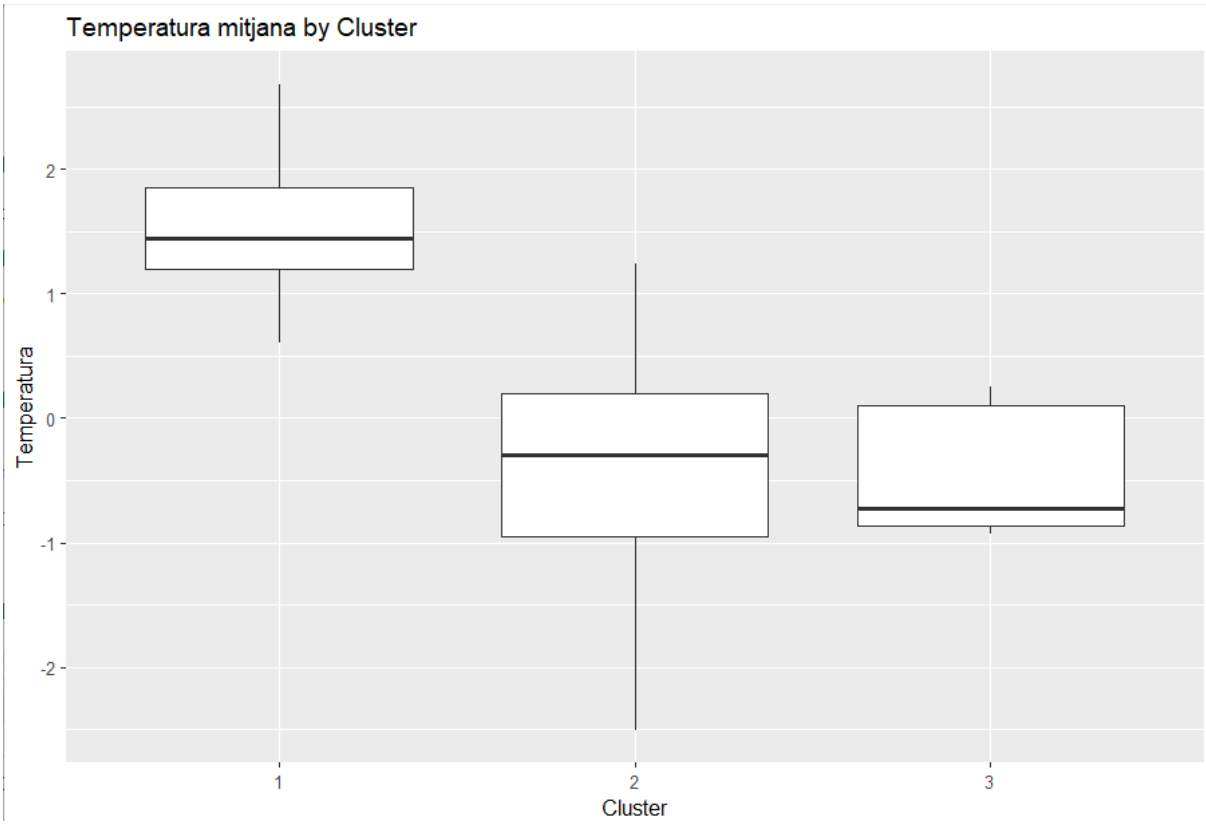

- La variable *pressure* també es diferencia fortament entre els tres clústers, especialmente entre el clúster 2 i els altres dos.

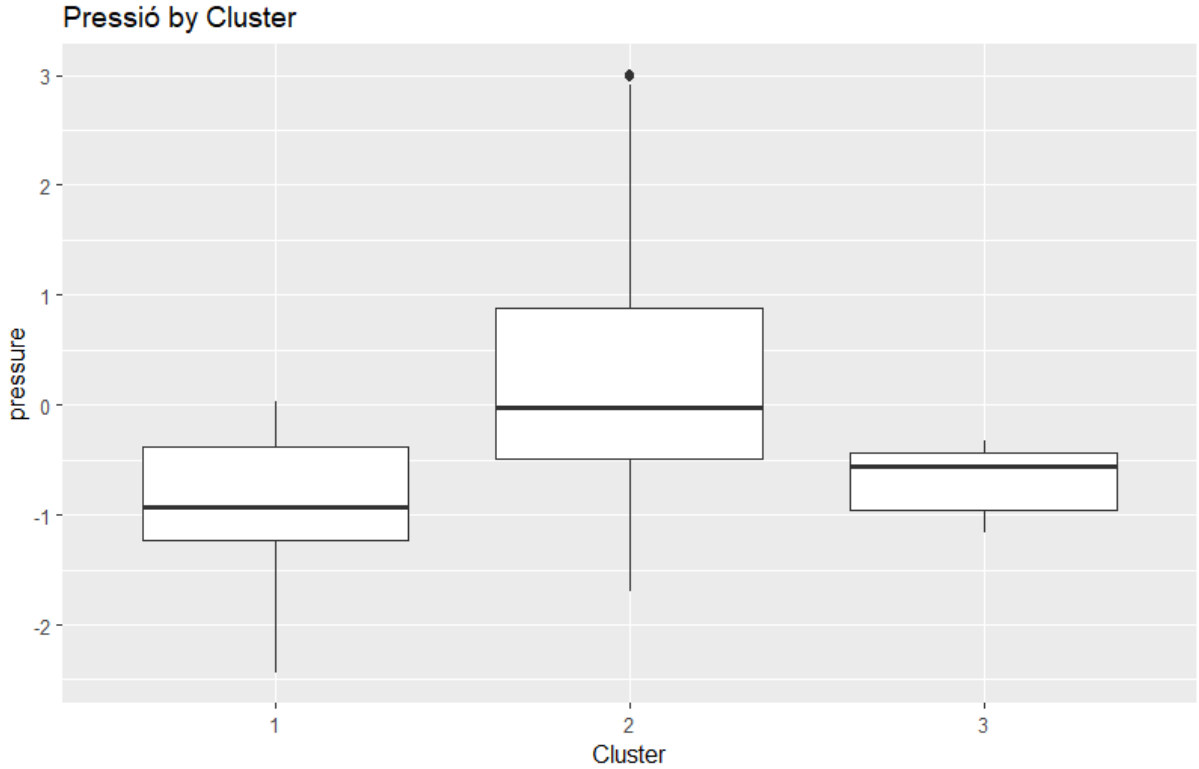

<u>Tests</u>

S’ha aplicat el test de Kruskal-Wallis per a comprobar si hi ha una diferència significativa entre els clusters per a cada variable analitzada. Els p-valors per a cada variable tenen un resultat inferior de 0’05, cosa que significa que aquesta diferència entre clusters es compleix per a cada variable.

En aquest gràfic també podem veure per cada cluster quina és la variable més significativa. Es pot veure que la temperatura mitjana té una gran importància en el primer i la pressió en el segon. Per contra la energia solar té una poca en el primer.

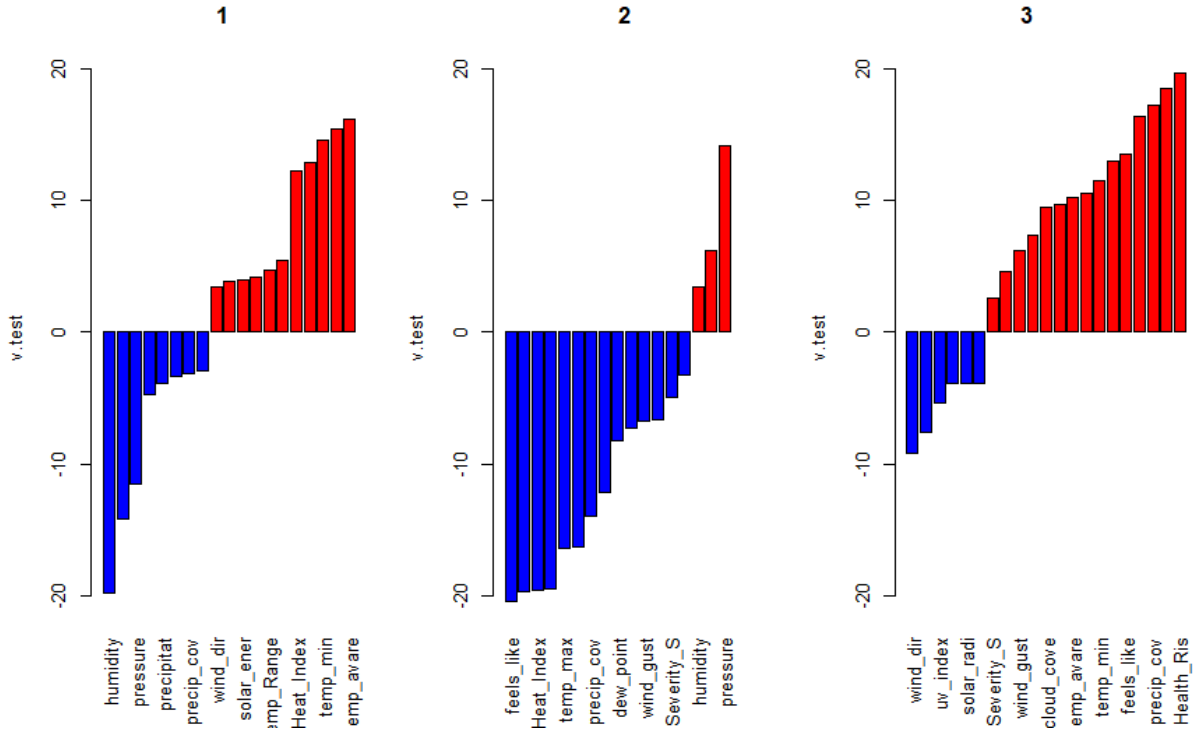

- Per a la temperatura mitjana, es confirma que la clusterització és correcta, ja que té un chi-squared molt elevat i un p-value molt baix. Això pot significar un patró climàtic concret segons diferentes variables com la ciutat i la humitat.

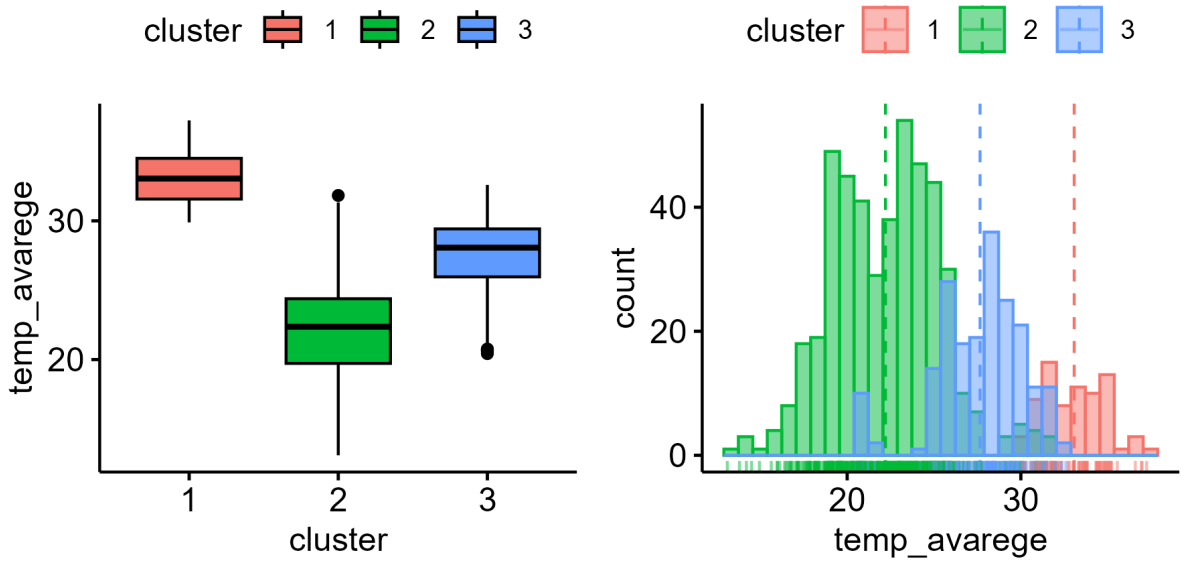


```
Kruskal-Wallis rank sum test

data:  current_var by d$cluster
Kruskal-Wallis chi-squared = 422.66,
df = 2, p-value < 2.2e-16
```

- Per a la pressió es confirma que aquest té clusters variats, i a més té una gran importància en el segon.

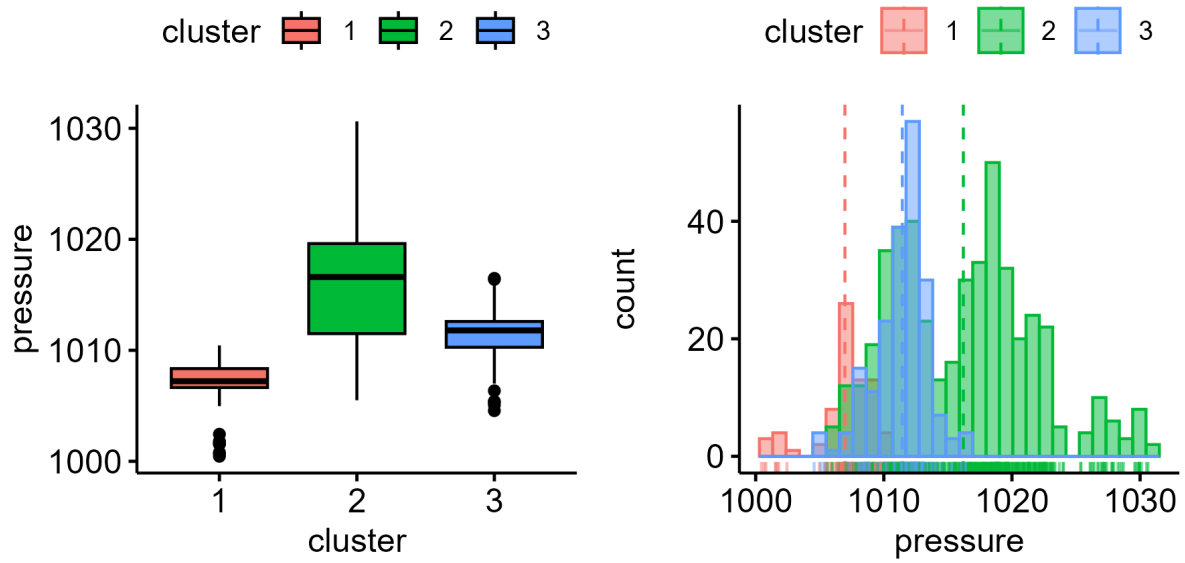


```
============  pressure  ================

      Kruskal-Wallis rank sum test

data:  current_var by d$cluster
Kruskal-Wallis chi-squared = 251.61, df = 2, p-value < 2.2e-16
```

- L'energia solar, per contra, no té tanta diferenciació, encara que el p-value ens confirma que en té, però no hi ha ningun cluster on destaqui.

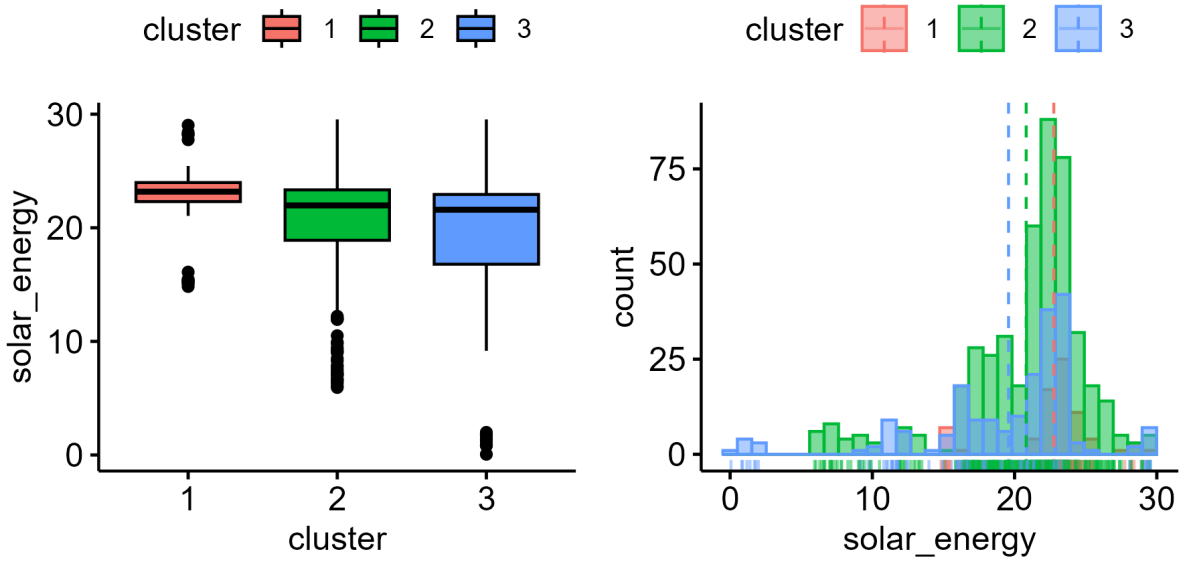


```
============  solar_energy  ================

	Kruskal-Wallis rank sum test

data:  current_var by d$cluster
Kruskal-Wallis chi-squared = 34.403, df = 2, p-value = 3.385e-08
```

7.2 Partitional Clustering

En fer un anàlisis de les variables per clúster del k-means, hem trobat alguns resultats interessants.

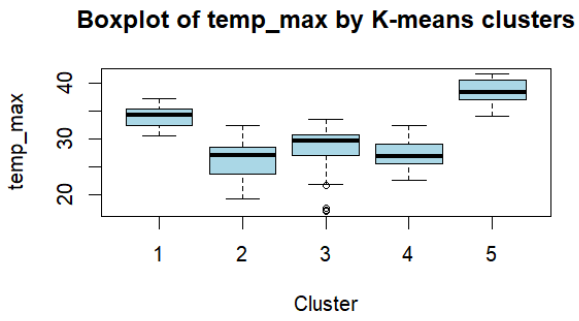

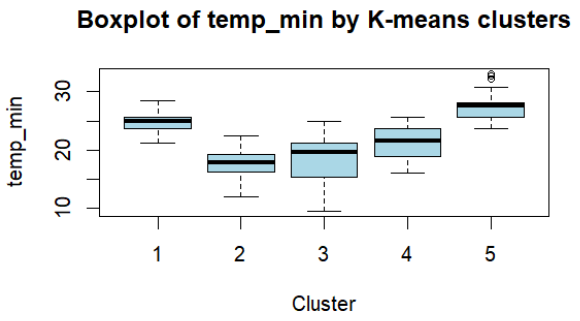

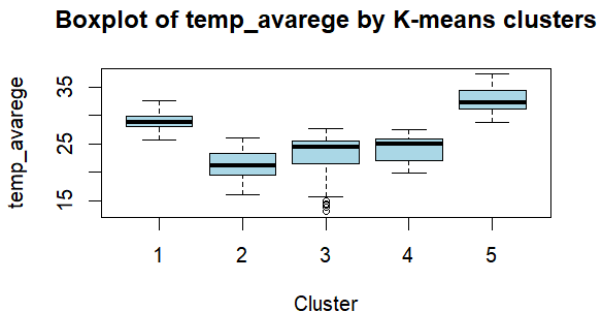

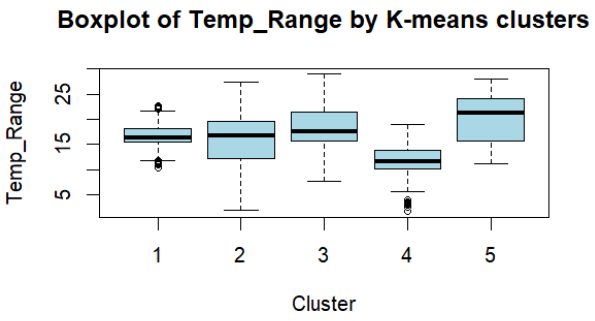

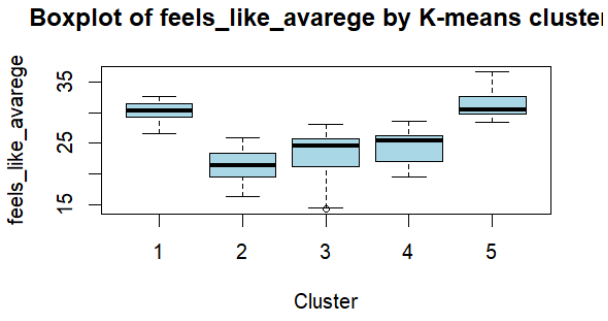

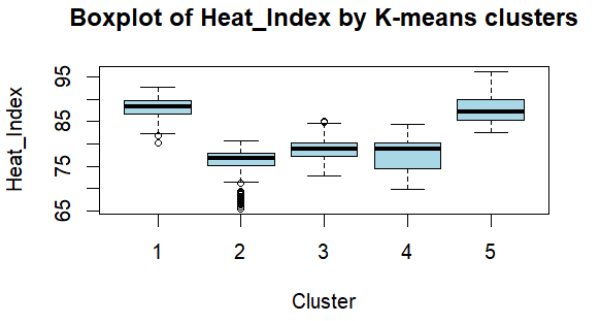

Com es pot observar, es veu una clara distinció amb una distribució molt semblant per a totes les variables relacionades amb la temperatura i el clima, sent els clústers 1 i 5 els més calents per un gran marge.

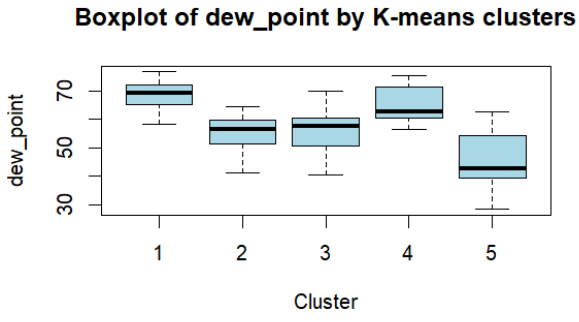

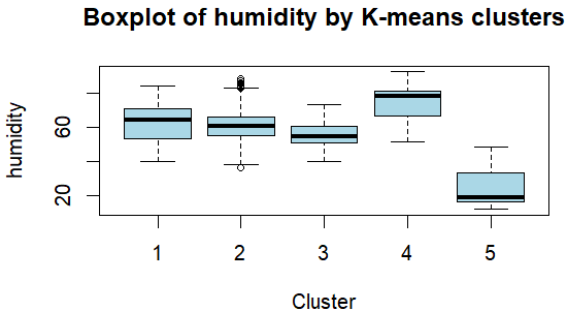

Sobre dew point i humidity, podem veure que el clúster 5 es diferencia per tenir una humitat distintivament baixa, en contrast amb la resta.

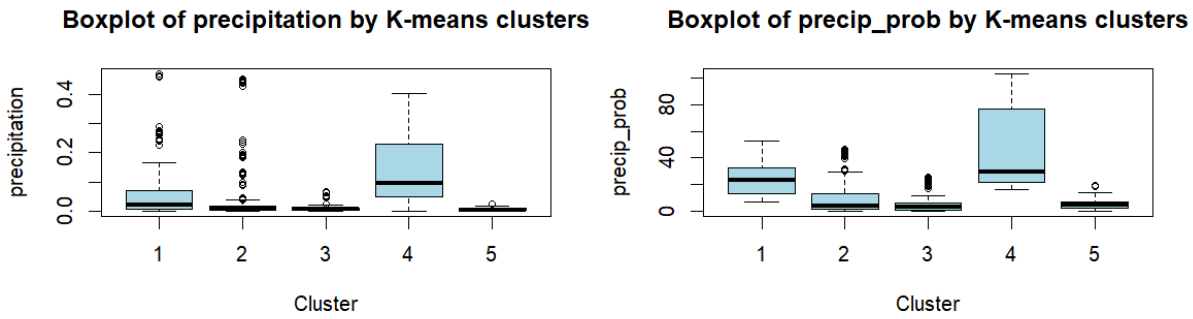

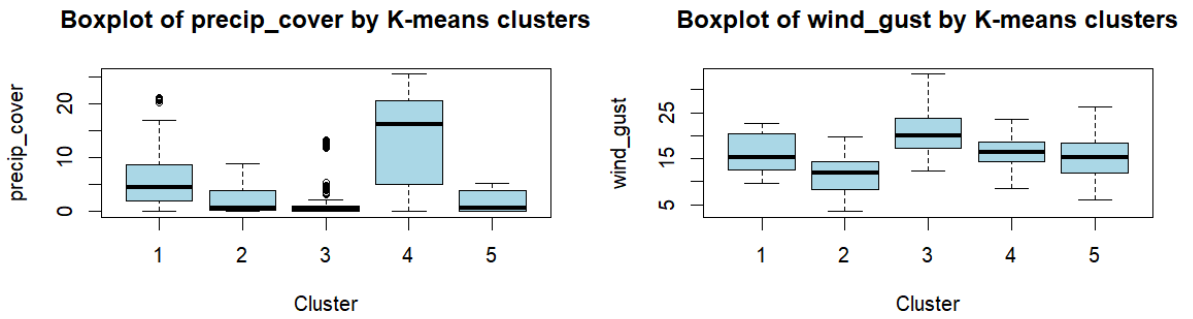

També es veu clar que al clúster 4 plou significativament més que a la resta.

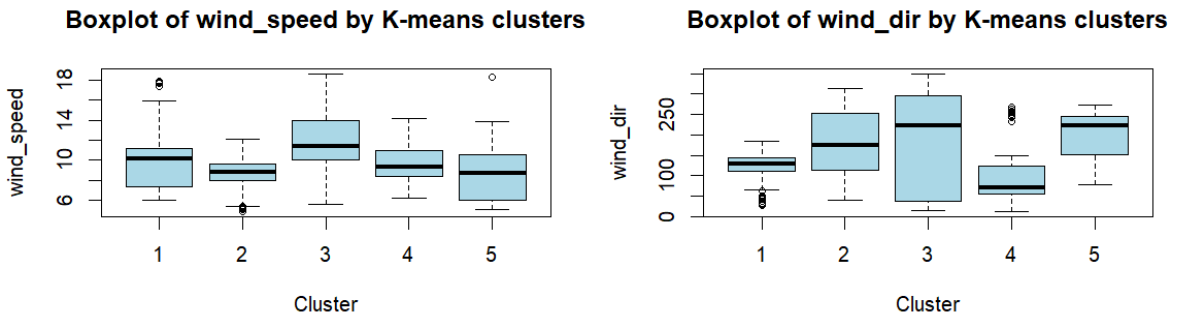

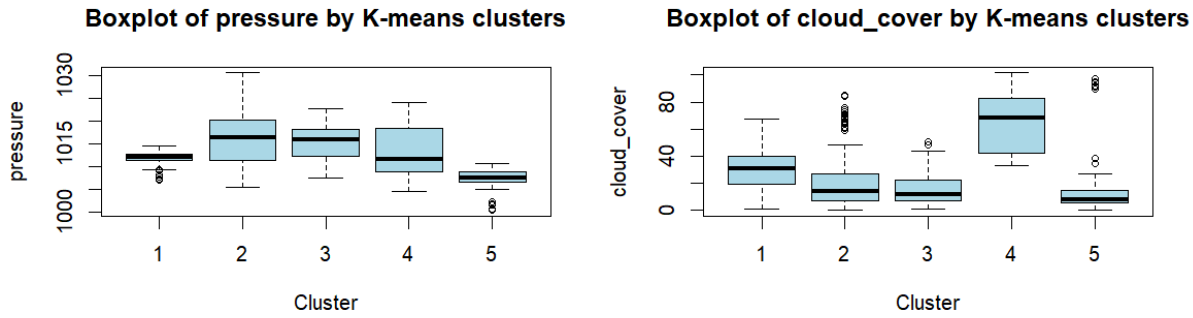

I en quant al vent, és clar que el clúster 3 és el que en té més en general.

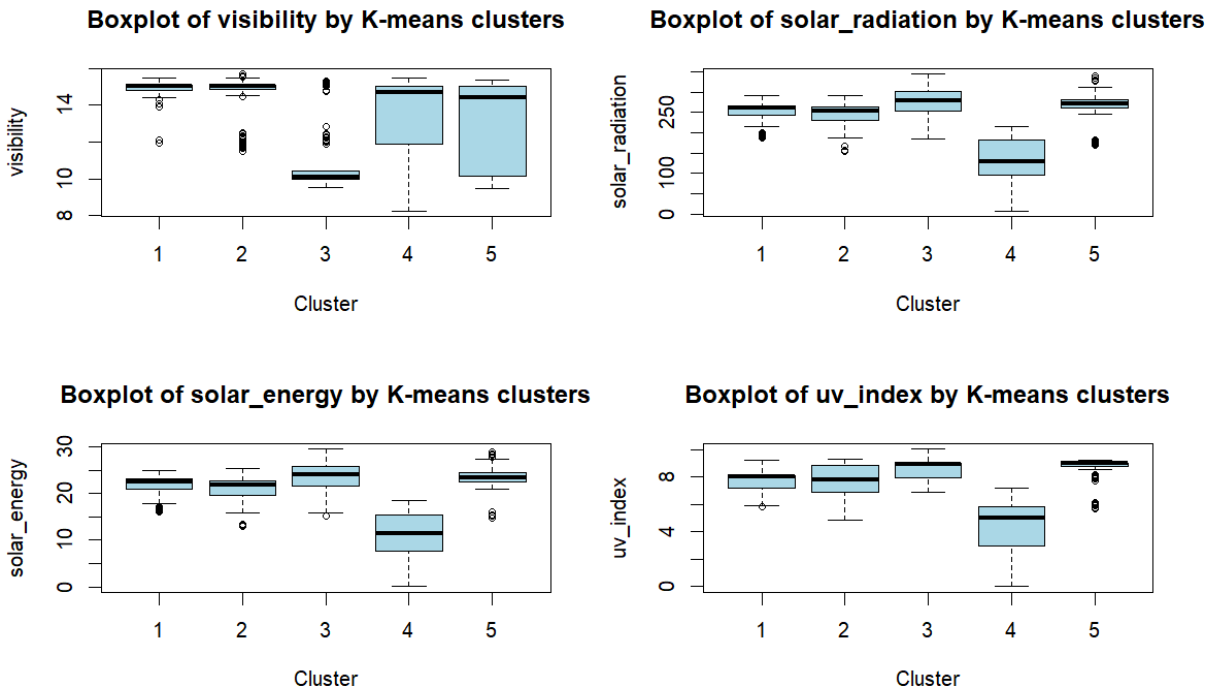

Com podiem esperar, al clúster 4, que abans hem vist que hi plovia molt, no hi toca tant el sol com a la resta.

7.3 Conclusions

Mitjançant el profiling hem pogut detectar clares diferències entre els clústers i treure'n conclusions sobre cadascun d'ells. Hem pogut observar clarament que fent servir el clustering podem crear perfils de diferents tipus de clima i simplificar massivament les dades, cosa que pot ser extremadament útil per la seva interpretació.

En el cas del clustering particional, hem pogut agrupar les observacions segons característiques compartides, com ara les variacions en la temperatura, la humitat, la qualitat de l'aire, i altres indicadors meteorològics rellevants. L'ús d'aquest mètode ens ha permès detectar patrons subjacents que no serien evidents simplement observant les dades originals. Per exemple, alguns clústers es van associar clarament a climes més freds i humits, característics de zones del nord, mentre que altres estaven més alineats amb climes càlids i secs, típics de regions del sud o del centre-oest.

D'altra banda, amb el clustering jeràrquic hem pogut observar una organització menys clara però amb un petit grup de variables clau que diferien entre clúster i clúster.

8. Discussions i Conclusions

Aquest estudi sobre fenòmens i estats climatològics als Estats Units ha abordat diversos tòpics mitjançant tècniques estadístiques i algorísmics, obtenint una gran varietat de resultats que poden proporcionar informació pràctica i rellevant.

Principals conclusions:

1. **Relacions entre condicions meteorològiques i salut pública i pluja:**

   Les anàlisis realitzades confirmen que factors atmosfèrics específics, com l'índex UV, la humitat, les precipitacions i les ràfegues de vent, tenen un impacte directe en el risc per a la salut pública, representat pel *Severity_Score*. Aquest descobriment és coherent, i pot valer la pena controlar aquestes variables com a indicadors de risc

   També hem pogut predir la pluja amb antelació basant-nos en altres fenòmens meteorològics.

2. **Clusterització i patrons regionals:**

   Les tècniques de clusterització jeràrquica i particional han revelat agrupacions significatives entre les observacions, vinculades en bona mesura a factors geogràfics i climàtics. Per exemple, s'ha identificat una forta associació entre les condicions meteorològiques del Sud i els clústers caracteritzats per temperatures altes i baixa humitat. Aquestes agrupacions poden utilitzar-se per desenvolupar estratègies regionals que abordin la qualitat de l'aire d'una manera més adaptada a les necessitats locals.

3. **Variabilitat estacional i predicció a curt termini:**

   En l'anàlisi de sèries temporals, la modelització ARMA ha permès caracteritzar patrons estacionals en les dades de qualitat de l'aire, fins i tot amb la limitada cobertura temporal inicial. Les transformacions realitzades, com la diferenciació estacional, han resultat essencials per ajustar correctament els models i obtenir prediccions fiables. Aquest enfocament podria expandir-se fàcilment a conjunts de dades més extensos per oferir prediccions contínues a curt i mitjà termini.

4. **Reducció de dimensionalitat amb PCA:**

   L'ús de PCA ha estat fonamental per reduir la dimensionalitat de les dades, seleccionant les variables més significatives sense perdre informació

rellevant. Els components identificats, com "solar_radiation" o "pressure," han capturat gran part de la variabilitat en el conjunt de dades, facilitant una millor interpretació dels resultats i incrementant l'eficiència computacional.

Futurs desenvolupaments:

A partir dels resultats obtinguts, ens plantegem la possibilitat d'aplicar models més avançats que puguin capturar relacions no lineals i interaccions més subtils entre variables.

Per exemple, podriem fer servir models més complexos com ensamblats o xarxes neuronals, integrar anàlisis basats en factors temporals i espacials, incorporant efectes de llarg termini i correlacions espacials en regions amb condicions similars, no limitant-nos a unes poques regions dels Estats Units d'Amèrica, i finalment podriem desenvolupar models híbrids analítics i estadístics.

Aquest projecte ens ha permès obtenir coneixement pràctic en l'anàlisi de dades i en l'ús de tècniques estadístiques com GLMz, PCA i sèries temporals. A més, hem hagut de treballar en equip, cosa que ens ha permès obtenir habilitats útils i tenir una bona experiència d'aprenentatge.

9. Expectations vs Reality

<u>Diagrama de Gantt esperat:</u>

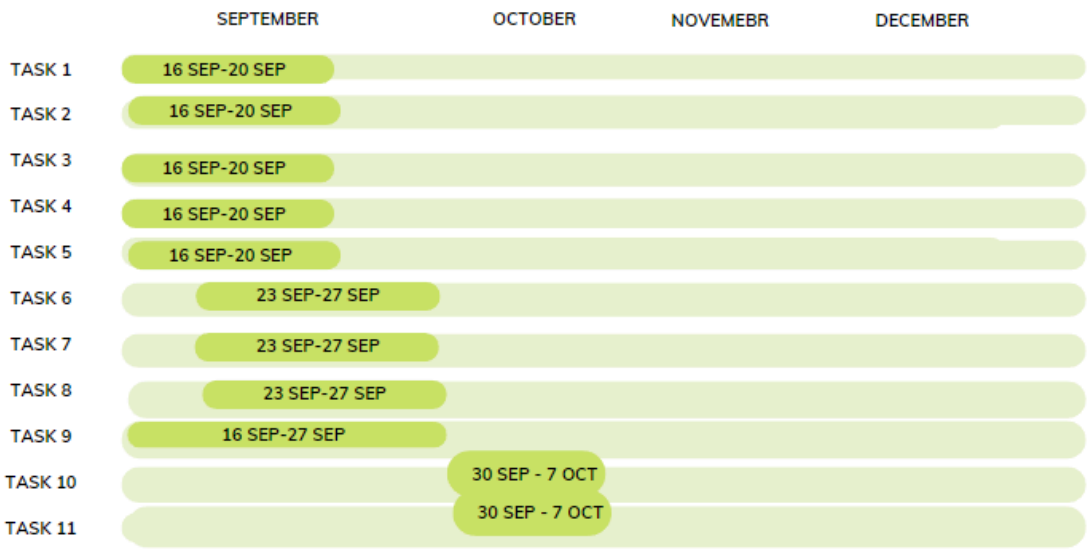

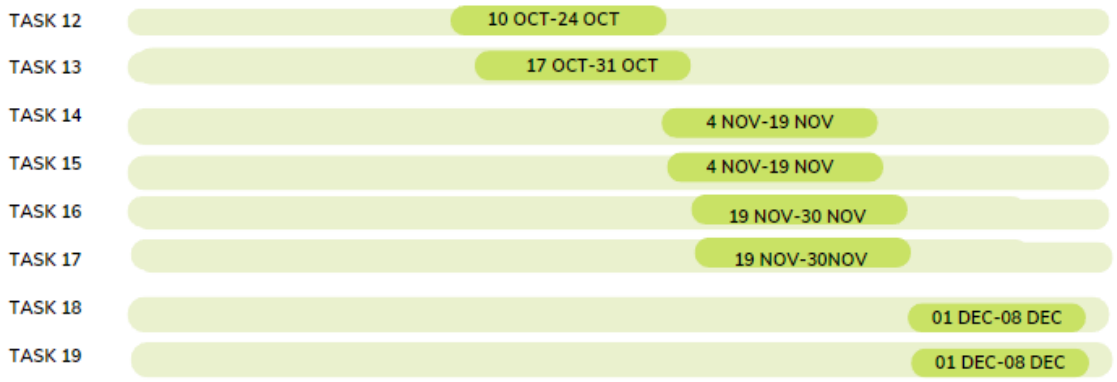

Diagrama de Gantt real:

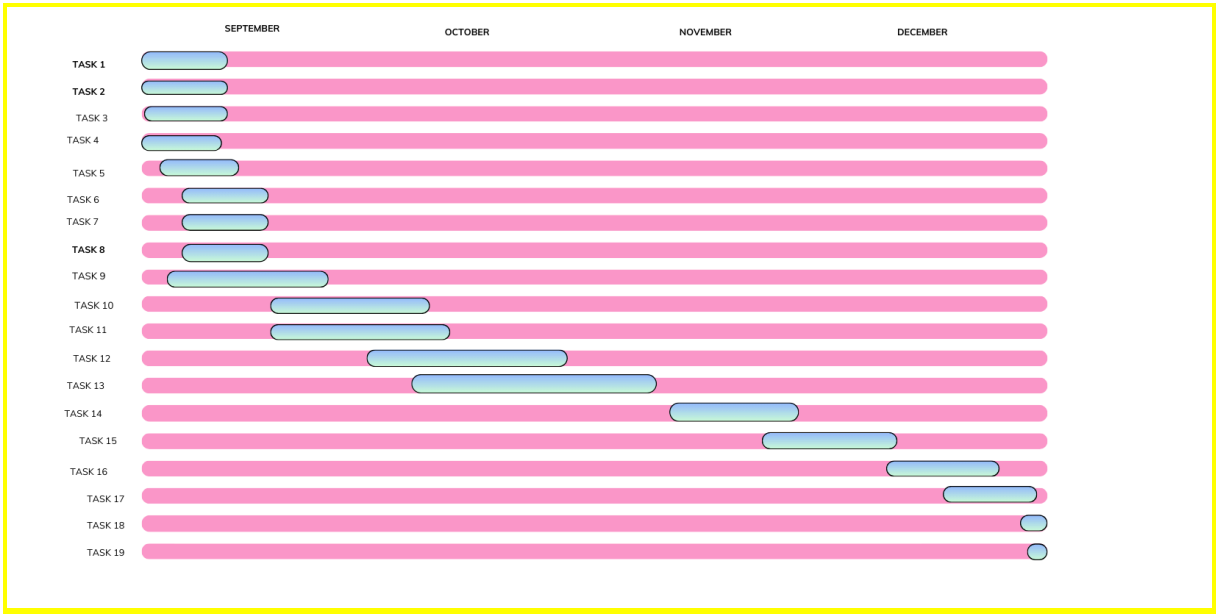

Les principals diferències respecte a l'organització i distribució de les tasques no han estat gaire significatives. Les tasques referents a la primera entrega (D4 PREPROJECT) vam trigar més a fer-les i algunes a començar-les, és a dir que portaven un petit retard acumulat, mentre que passada la primera entrega portaven les tasques molt més al dia i inclús amb més antelació de la que teníem pensada. A més, com les dades de finalització del projecte han set ajornades, havíem considerat en un principi que aquest hauria estat acabat pel 8 de decembre aproximadament.

Divisió de tasques:

Participant	**Mariona**	**Raúl**	**Marc**	**Núria**	**Joan**
D2.Task 1: Find database	x	x	x	x	x
D2. Task 2: Analyze variables	x			x	
D2. Task 3: Find missing data		x	x		x
D2. Task 4: Process of getting the data and content	x			x	
D2. Task 5: Metadata File	x			x	
D3. Task 6: Gantt diagram			x		
D3. Task 7: Division of tasks			x		
D3. Task 8: Risk contingency plan			x		
D4. Task 9: Preprocessin g	x	x	x	x	x
D4. Task 10: Univariate descriptive statistics	x		x		x
D4. Task 11: Bivariate descriptive statistics		x		x	

D4. Task 12: Generalized Linear Models	x	x	x		
D4. Task 13: Time series				x	x
D5. Task 14: PCA analysis for numerical variables	x			x	
D5. Task 15: Hierarchical CLustering on original data		x	x		x
D5. Task 16: Partitional Clustering	x	x	x		
D5. Task 17: Profiling of clusters				x	x
D5. Task 18: Discussion and conclusions	x	x	x	x	x
D6. Task 19: Final Gantt and risks			x		

<u>Risk contingency plan</u>

Risk	**How to prevent**	**How to manage**
A member of the group leaves the course.	Make sure that all the tasks are realized by more than one person.	Reallocate the tasks that have been damaged.
Too much missing data.	Choosing a database with a low percentage of missing data.	Minimizing the impact of the missing data using statistical methods and preprocessing.

Graphics don’t give enough information.	Pick a clear database with manageable structures.	Using appropriate tools to make the most of it.
Too few usable variables.	Ensure that the variables of the database are significant.	Try to change the perspective of the plan in a way that the variables are important.